

Evaluación Exhaustiva de Alternativas Metodológicas para la Localización Débilmente Supervisada en Úlceras de Pie Diabético

1. Contextualización del Desafío Técnico y Clínico

El desarrollo de sistemas de diagnóstico asistido por computadora para la clasificación y segmentación de úlceras de pie diabético (UPD) representa uno de los desafíos más complejos en el análisis de imágenes médicas. El proyecto en curso, denominado Co-MIL, plantea una arquitectura basada en el paradigma de Aprendizaje Multi-Instancia (MIL), utilizando un extractor de características MobileNetV2 congelado y un mecanismo de atención extendido a múltiples ramas. La transición desde un enfoque previo completamente supervisado (utilizando arquitecturas densas como ResUnet y Unet++ sobre el conjunto de datos FUSeg/DFUTissue) hacia un paradigma de supervisión débil motivado por la escasez de datos etiquetados a nivel de píxel introduce fricciones matemáticas y arquitectónicas significativas.

El obstáculo central diagnosticado con precisión empírica en el entorno de validación revela que el mecanismo de atención espacial exhibe un contraste mediano de 0.04 en una escala normalizada de 0 a 1. Este comportamiento plano indica un colapso total de la capacidad del modelo para localizar características discriminativas, anulando el propósito clínico del sistema. El diagnóstico de la causa raíz identifica que el 97.8% de las regiones de interés (ROIs), anotadas mediante cajas delimitadoras, son internamente homogéneas, conteniendo un único tipo de tejido. Alternativamente, cuando las lesiones presentan morfologías alargadas o irregulares, las anotaciones rectangulares encapsulan porciones significativas de piel sana que actúan como ruido espacial, dificultando la separación semántica entre el tejido patológico y el fondo.

Este documento presenta una investigación profunda y crítica sobre las fronteras metodológicas de 2025 y 2026 que abordan explícitamente el colapso de atención en bolsas MIL homogéneas, evalúa el estado del arte en segmentación de heridas crónicas con conjuntos de datos restringidos, analiza empíricamente la viabilidad de modelos fundacionales de segmentación recientes como SAM2 en dominios dermatológicos y establece una hoja de ruta jerarquizada para el rediseño y despliegue del sistema bajo estrictas restricciones de hardware y tiempo.

2. Anatomía Matemática del Colapso de Atención en Bolsas Homogéneas

Para formular una solución metodológica efectiva, es imperativo desglosar el fallo matemático subyacente del mecanismo Gated Attention MIL propuesto originalmente por Ilse et al. (2018).

En este paradigma, una bolsa X está compuesta por N instancias o parches $\{x_1, x_2, \dots, x_N\}$. El modelo de atención calcula un peso a_k para cada instancia utilizando una función de activación pre-softmax, típicamente una proyección lineal seguida de activaciones hiperbólicas y sigmoides, que culmina en una capa Softmax para asegurar que la suma de los pesos sea igual a 1.

La función Softmax está matemáticamente diseñada para crear competición entre los elementos de entrada. En escenarios tradicionales de histopatología computacional, como la detección de metástasis en ganglios linfáticos, una bolsa (una imagen de portaobjetos completo) contiene miles de parches, de los cuales solo uno o dos exhiben morfología maligna. La varianza en el espacio latente es inmensa, y la red aprende a maximizar la activación pre-softmax de los parches malignos, empujando su peso de atención hacia un valor cercano a 1, mientras que los miles de parches de tejido sano son empujados hacia 0¹.

En el contexto específico de las úlceras de pie diabético analizadas en el proyecto Co-MIL, las condiciones topológicas son diametralmente opuestas. Dado que las bolsas se construyen a partir de ROIs pequeñas y recortadas manualmente, la distribución de características latentes de los parches dentro de la bolsa presenta una varianza estadísticamente insignificante. Si una

caja delimitadora captura exclusivamente tejido de granulación, los N parches (por ejemplo, recortes de 112px o 224px) producirán vectores de características casi idénticos al pasar por el extractor MobileNetV2 congelado.

Cuando estos vectores idénticos se alimentan a la red de atención, las proyecciones

pre-softmax resultan en valores escalares equivalentes. Al aplicar la función Softmax sobre N valores idénticos, la distribución colapsa inevitablemente en una probabilidad uniforme de

$1/N$ para cada parche. Si una bolsa se divide en 16 parches, cada parche recibirá un peso de atención de aproximadamente 0.0625. La diferencia entre el valor máximo y el mínimo (el contraste de atención) tiende a cero, lo cual se alinea perfectamente con la medición empírica de 0.04 observada en el conjunto de prueba. Este colapso no es un defecto de entrenamiento, sino el comportamiento matemático esperado de la función Softmax ante entradas carentes de heterogeneidad interna³.

Adicionalmente, cuando las lesiones irregulares se fuerzan en anotaciones rectangulares, se introduce una gran cantidad de piel sana. El mecanismo de atención, al buscar desesperadamente patrones discriminativos para minimizar la pérdida de clasificación de la bolsa, a menudo desarrolla correlaciones espurias, asignando pesos elevados a los bordes del rectángulo, a sombras o a texturas epidérmicas que no guardan relación causal con el tejido patológico, un fenómeno ampliamente documentado en la literatura de 2025 y 2026 como "concentración de atención por factores de confusión"⁵.

3. Alternativas Metodológicas para la Resolución del Colapso de Atención (2025-2026)

La comunidad científica ha identificado las limitaciones estructurales de la agregación basada

en atención y ha desarrollado, entre 2025 y 2026, marcos teóricos e implementaciones que abordan explícitamente el colapso de información en bolsas homogéneas y el sobreajuste a correlaciones espurias. Estas soluciones se presentan evaluadas críticamente bajo las restricciones del proyecto: viabilidad en CPU, despliegue ligero y un conjunto de datos inferior a 300 imágenes.

3.1 Sustitución de Softmax por Sigmoide Normalizada (ASMIL)

La investigación publicada en 2026 bajo el marco ASMIL (Attention-Stabilized Multiple Instance Learning) diagnostica precisamente el problema de las distribuciones de atención oscilantes y sobre-concentradas. Los autores demuestran que reemplazar la función Softmax por una función Sigmoide Normalizada elimina la restricción de suma unitaria que deprime artificialmente los pesos en bolsas con múltiples instancias positivas³.

En lugar de forzar a los parches a competir entre sí, la función Sigmoide evalúa la probabilidad absoluta de que cada parche individual contenga características de la clase objetivo. Si una bolsa contiene 16 parches y todos corresponden a tejido de callo, la función Sigmoide puede asignar a todos un valor de atención de 0.9. Posteriormente, los pesos se normalizan para la agregación, pero la magnitud relativa del contraste espacial frente al fondo (si lo hubiera) se preserva³. Esta modificación aborda directamente la homogeneidad interna: permite que la red reconozca que todo el interior de la bolsa es importante, mejorando la coherencia espacial de los clasificadores de las 12 ramas independientes.

3.2 Maximización de la Entropía de Atención (AEM)

El marco AEM (Attention Entropy Maximization), introducido a finales de 2024 y aceptado formalmente en MICCAI 2025, es una técnica de regularización de diseño ultraligero concebida para mitigar el sobreajuste y la concentración extrema de la atención sin introducir un solo parámetro entrenable adicional⁷.

El mecanismo de AEM integra un término de entropía negativa sobre los valores de atención en la función de pérdida global. Matemáticamente, la pérdida se formula como la suma del error de clasificación estándar y el término de entropía: $L_{total} = L_{ce} + \lambda \sum a_n \log a_n$, donde λ es un parámetro de recocido (annealing) que pondera la penalización. Esta regularización fuerza matemáticamente al modelo a distribuir el peso de atención de manera más equitativa durante las primeras etapas del entrenamiento, evitando que la red colapse rápidamente sobre un atajo visual (como la piel sana en el borde del parche)⁹.

Para el caso específico de Co-MIL, AEM es fundamentalmente atractivo porque es un método de tipo *plug-and-play*. No requiere alterar la arquitectura de Gated Attention preexistente ni añadir módulos convolucionales que incrementen la carga computacional en CPU. Sin embargo, su capacidad para generar contraste en bolsas estrictamente homogéneas es teóricamente limitada; AEM obliga a la dispersión de la atención, lo que podría aplanar aún más los mapas si la bolsa completa carece de varianza. Su verdadera utilidad en este proyecto radica en aplicarlo a las bolsas heterogéneas (aquellas con mucho relleno de piel) para obligar a la red a explorar el tejido patológico en lugar de colapsar sobre el ruido epidérmico perimetral⁹.

3.3 Transición a la Causalidad: FocusMIL y el Retorno al Max-Pooling

La literatura de 2025 presenta un análisis disruptivo proveniente de la inferencia causal, materializado en la arquitectura FocusMIL. Los investigadores argumentan teóricamente que los métodos basados en atención violan la suposición estándar del aprendizaje multi-instancia porque agregan información de todas las instancias, permitiendo que la red utilice "evidencia negativa" (patrones que correlacionan con la ausencia de enfermedad) para clasificar bolsas positivas⁶.

En el conjunto de datos de úlceras, esto ocurre cuando la piel sana ("relleno") deprime la puntuación global de la bolsa, confundiendo a los clasificadores de las ramas específicas de tejido. FocusMIL propone abandonar la atención ponderada y retornar al Max-Pooling tradicional, donde la puntuación de la bolsa está dictada exclusivamente por la instancia con la activación máxima. Esto elimina la influencia del tejido de fondo o de relleno en la decisión de la bolsa. Para evitar el defecto histórico del Max-Pooling (el sobreajuste extremo a características singulares), FocusMIL introduce un Cuello de Botella de Información Variacional (VIB) a nivel de instancia y un esquema de mini-lotes multi-bolsa que estabiliza la optimización⁴.

Al forzar un cuello de botella informacional, la red debe descartar los detalles de alta frecuencia irrelevantes (como variaciones de iluminación o artefactos de anotación) y retener únicamente los factores causales verdaderos del tejido. Bajo restricciones de CPU y conjuntos de datos pequeños, la eliminación del mecanismo de atención multicapa a favor de un operador máximo reduce sustancialmente el número de operaciones de punto flotante por segundo (FLOPs), optimizando tanto el entrenamiento iterativo como la latencia de inferencia futura en dispositivos embebidos⁴.

3.4 Agregadores de Transformadores Ultraligeros (QG-MIL)

Publicado en 2026, QG-MIL (Qwen Gated Multiple Instance Learning) aborda la concentración de atención trasladando técnicas probadas en Modelos de Lenguaje de Gran Escala (LLMs) al dominio del análisis de imágenes médicas. Los autores observaron que el colapso de atención en MIL es isomorfo al colapso de información en transformadores densos⁵.

QG-MIL reestructura el bloque de agregación incorporando una pre-normalización basada en RMSNorm, normalización cruzada de consultas y claves (QK Normalization), puertas de salida de atención de grano fino, y módulos de retroalimentación (feed-forward) con activaciones de tipo SwiGLU⁵. Estas decisiones de diseño arquitectónico distribuyen la atención de manera uniforme a través de las instancias sin requerir pérdidas auxiliares, como en AEM, ni enfoques de regularización multi-etapa.

Resulta particularmente relevante para Co-MIL la existencia de la variante "QG-MIL Light", la cual reduce la dimensión oculta y opera con apenas 2.4 millones de parámetros¹³. Esto lo sitúa en una escala de complejidad computacional equivalente al extractor MobileNetV2, haciéndolo plenamente viable para despliegues restringidos de memoria. La evaluación empírica de 2026 demostró que QG-MIL exhibe un rendimiento sobresaliente independientemente del tamaño de la bolsa, abarcando desde patología de portaobjetos completos (miles de instancias) hasta hematología celular (cientos de instancias, análogo a los parches de las ROIs de heridas)⁵.

Arquitectura	Mecanismo de	Compatibilida	Eficacia en	Nivel de
--------------	--------------	---------------	-------------	----------

Analizada	Intervención	d CPU / Embebido	Bolsas Homogéneas / Ruidosas	Complejidad de Implementación
ASMIL (Sigmoide Normalizada)	Reemplazo de Softmax por Sigmoide con normalización cruzada.	Extremadamente Alta. Disminuye la complejidad computacional al evitar la competición de parches.	Resuelve la depresión matemática de los pesos en bolsas 100% homogéneas. Permite que múltiples parches puntúen alto independientemente.	Trivial. Modificación directa en la última capa de activación del módulo Gated Attention existente.
AEM (Attention Entropy)	Integración de un término de pérdida entrópica global ($-H(A)$) ponderado por recocido.	Muy Alta. Solo añade una suma logarítmica durante la propagación hacia atrás. No impacta la inferencia.	Penaliza la hiper-concentración en artefactos de ruido (bordes de cajas), pero puede no generar contraste diferencial en bolsas donde todo es tejido idéntico.	Baja. Requiere añadir pocas líneas de código a la definición de la función de coste y monitorear el hiperparámetro λ .
FocusMIL (Max-Pooling + VIB)	Eliminación de la atención ponderada. Uso de cuello de botella variacional e inferencia causal sobre máxima	Alta. Reduce el paso de agregación a una operación matricial de máximo, ideal para ONNX/TFLite en hardware	Inmuniza el modelo contra la evidencia negativa (el ruido del "relleno" de piel no penaliza la activación del	Media. Exige reescribir la capa de agregación MIL y estructurar un entrenamiento basado en inferencia

	activación.	de borde.	tejido patológico real).	variacional.
QG-MIL Light	Transformador con RMSNorm, normalización QK y SwiGLU en 2.4M de parámetros.	Media-Alta. Viable en inferencia móvil, pero el entrenamiento de transformadores desde cero en CPU es marcadamente más lento.	Altamente resistente al colapso de atención y validado en escalas de bolsas pequeñas (hematología). Promueve distribuciones estables.	Alta. Requiere la sustitución completa del módulo ABMIL y la adaptación de las dimensiones de los tensores de entrada.

4. Estado del Arte en Localización Débilmente Supervisada de Heridas Crónicas (2025-2026)

Para establecer expectativas realistas sobre el rendimiento alcanzable en la clasificación y segmentación de úlceras de pie diabético utilizando conjuntos de datos en el rango de decenas a cientos de imágenes, es imperativo analizar los avances más recientes en la literatura especializada. La comunidad ha reconocido abrumadoramente que la obtención de anotaciones a nivel de píxel realizadas por especialistas médicos es un cuello de botella insostenible, dirigiendo la investigación hacia arquitecturas que maximicen la señal débil y se adapten a despliegues móviles.

En 2026, un estudio pionero integró mecanismos de Atención de Coordenadas (Coordinate Attention) con la arquitectura ConvNeXt para la clasificación de estados patológicos en úlceras de pie diabético. Este modelo optimiza la utilización de parámetros extrayendo dependencias espaciales a largo plazo en direcciones horizontales y verticales. Evaluado en un conjunto de datos estandarizado de aproximadamente 800 imágenes (un orden de magnitud comparable al límite teórico del proyecto Co-MIL), la arquitectura alcanzó precisiones superiores al 97% en clasificación a nivel de imagen¹⁴. Sin embargo, los investigadores enfatizaron que la transición hacia métodos puramente débilmente supervisados para inferir mapas de localización espacial reduce significativamente la confianza geométrica de los contornos, confirmando que las métricas de segmentación clásicas (como el coeficiente Dice) no reflejan adecuadamente la utilidad del diagnóstico predictivo.

En el contexto de la viabilidad móvil, Hoang et al. publicaron a finales de 2025 un desarrollo basado en arquitecturas de Vision Transformers ultraligeros (ViT-Small, 22 millones de

parámetros) enfocado en la clasificación de patologías de isquemia e infección en el pie diabético¹⁶. La contribución fundamental de este trabajo fue el despliegue del modelo en un dispositivo periférico comercial (iOS) sin aplicar compresión degenerativa. El sistema procesó las inferencias en tiempos oscilantes entre 50 y 80 milisegundos por imagen, manteniendo una precisión diagnóstica de grado de investigación en aplicaciones de punto de atención clínica (Point-of-Care)¹⁶. Este antecedente consolida la premisa de que restringir el proyecto a arquitecturas ligeras como MobileNetV2 para su ejecución en procesadores integrados es un objetivo científico sumamente relevante y altamente publicable.

Respecto a las métricas de rendimiento en tareas de segmentación y localización precisa, los resultados del certamen internacional *Diabetic Foot Ulcers Challenge 2024* (cuyos protocolos técnicos se diseminaron durante 2025) arrojan luz sobre el techo metodológico actual. Las propuestas ganadoras del desafío, que utilizaron variaciones de mapas de activación de clase (CAM) refinados con arquitecturas pseudo-supervisadas, reportaron índices Dice en el conjunto de prueba oculto que rondaron un modesto 0.48¹⁷. Este dato es de vital importancia estructural para la formulación de la tesis: esperar que un modelo entrenado con menos de 300 imágenes anotadas débilmente supere o iguale el 78.6% de Dice obtenido en el trabajo anterior completamente supervisado con 1000 imágenes es una expectativa estadísticamente irrealizable. La frontera del conocimiento actual en localización con etiquetas débiles para este dominio médico se ubica firmemente en el rango de un Dice de 0.40 a 0.55.

5. Viabilidad de Modelos Fundacionales de Segmentación (SAM2 / MedSAM2)

La utilización de modelos fundacionales de segmentación visual de propósito general, particularmente el Segment Anything Model 2 (SAM2) y sus iteraciones derivadas (MedSAM2, FATE-SAM2, Medical SAM 2), para la generación automatizada de pseudo-máscaras densas a partir de cajas delimitadoras, se presenta como una hipótesis de trabajo natural dadas las restricciones de anotación. No obstante, evaluaciones exhaustivas efectuadas en 2025 y 2026 sobre imágenes médicas revelan que su aplicabilidad en escenarios de inferencia *zero-shot* es severamente limitada.

SAM2 fue diseñado principalmente para procesar videos o volúmenes tridimensionales continuos (como tomografías computarizadas), apoyándose en un banco de memoria secuencial para propagar predicciones espaciales¹⁸. En entornos radiológicos con alto contraste estructural, la incitación mediante cajas ("box prompts") produce resultados aceptables. Sin embargo, múltiples estudios independientes documentan que el rendimiento *zero-shot* de SAM2 se degrada catastróficamente frente a texturas médicas complejas, especialmente en modalidades ópticas de superficie como la dermatoscopia y la fotografía clínica de heridas¹⁹.

El fracaso estructural de SAM2 y MedSAM2 en este dominio se fundamenta en la ambigüedad morfológica y la falta de gradientes abruptos. La transición entre el tejido de granulación saludable y un borde epitelial, o entre la esfacelo y la fibrina dentro de una úlcera diabética, ocurre a través de gradientes de color difusos y sutiles cambios texturales. Cuando se proporciona una caja delimitadora rectangular que abarca una lesión amorfa junto con

porciones de piel circundante sana, el mecanismo de codificación de prompts de SAM2 asume frecuentemente que la piel sana es parte de la región objetivo, o colapsa aislando elementos de alta saliencia fotográfica pero irrelevantes clínicamente, como coágulos hemorrágicos periféricos o reflejos especulares del flash¹⁸.

La literatura más reciente de 2026 (por ejemplo, el modelo unificado MedPixel) señala que para estabilizar SAM2 en este tipo de modalidades, se requiere un ajuste fino a gran escala (Parameter-Efficient Fine-Tuning) sobre grandes corpus de imágenes del dominio objetivo o el uso de arquitecturas de aprendizaje en contexto (*Few-Shot*) que exigen integrar máscaras perfectas en el banco de memoria inicial de la red²⁰. Dado que el entorno de entrenamiento para el proyecto Co-MIL está limitado a la disponibilidad de CPU (o acceso efímero a Google Colab) y la base de datos se restringe exclusivamente a cajas delimitadoras, someter a los codificadores de imágenes Hiera de SAM2 a un ajuste fino denso es prohibitivo por costos de memoria y tiempo computacional.

Por consiguiente, se concluye críticamente que depender de SAM2 o SkinSAM sin ajuste fino pesado para extraer máscaras de entrenamiento confiables introducirá un nivel de ruido geométrico en el bucle de retroalimentación de la red que superará cualquier beneficio derivado del pseudo-etiquetado. Para este estadio de la investigación (prototipado ágil en pocos días), el uso de SAM2 debe descartarse metodológicamente.

6. Despliegue en Hardware de Borde (Edge Computing): Limitaciones y Oportunidades

Una restricción inamovible definida en la taxonomía del proyecto es la viabilidad del modelo final para su ejecución en entornos de cómputo embebido, tales como plataformas Raspberry Pi o microcontroladores análogos, utilizando los entornos de ejecución ONNX Runtime o TensorFlow Lite (TFLite). Esta restricción excluye axiomáticamente arquitecturas complejas de atención topológica como Geo-MIL o grafos dinámicos.

Las Redes Convolucionales de Grafos (GCN) dependen de la construcción de matrices de adyacencia en tiempo de ejecución para modelar las relaciones topológicas de los tejidos²⁴. La generación dinámica de estas matrices y las operaciones de mensaje-paso (message-passing) introducen un determinismo variable que rompe las estructuras estáticas exigidas por el grafo computacional de exportación de ONNX²⁶. Forzar la exportación de GNNs hacia dispositivos de borde frecuentemente resulta en la imposibilidad de utilizar las optimizaciones del nivel de ensamblador, penalizando el uso de la memoria RAM, un recurso extremadamente limitado en procesadores ARM de bajo consumo.

En contraste, el uso de la arquitectura base MobileNetV2 acoplada con capas de agregación lineales o basadas en máximo (Max-Pooling) representa el pináculo de la eficiencia perimetral. Los despliegues documentados a lo largo de 2025 y 2026 sobre la familia Raspberry Pi 4 y 5 con modelos de la clase MobileNetV2 (optimizados a precisión FP16 mediante cuantización nativa) arrojan latencias de inferencia sostenidas de 70 a 110 milisegundos por fotograma²⁷. Estas métricas de rendimiento aseguran una capacidad de diagnóstico en tiempo cuasi-real, confirmando que preservar la simplicidad del módulo de agregación no solo es una conveniencia durante el desarrollo basado en CPU, sino un requisito técnico para cumplir la

meta de portabilidad final de la tesis³⁰.

7. Plan Estratégico y Priorización Metodológica para Ejecución a Corto Plazo

De acuerdo con el análisis de la literatura y las restricciones impuestas por el cronograma inminente de revisión (evaluaciones prototipables en un día versus implementaciones de mediano plazo), se presenta la siguiente categorización priorizada para resolver el colapso de la atención y optimizar la localización.

Prioridad Estratégica	Intervención Metodológica	Fundamentación Aplicada al Contexto Co-MIL	Ventana de Implementación	Cita Científica de Referencia (Para Justificación de Tesis)
1 (Crítica Inmediata)	Modificación de Arquitectura a ASMIL (Sustitución de Función Sigmoide)	La homogeneidad masiva de las ROIs de la úlcera (97.8% de un solo tejido) destruye el mecanismo de competición de Softmax. Cambiar la capa final de la atención por una función sigmoide independiente para cada parche permite puntuaciones altas de forma universal, restaurando el contraste topológico subyacente.	1 Día (Prototipable Mañana). Se implementa alterando una única línea de código en la función de activación final del módulo Gated Attention en PyTorch, eliminando el requerimiento de suma a la unidad.	Zhang, Y. et al. (2026). <i>Attention-Stabilized Multiple Instance Learning for Whole Slide Image Classification</i> . arXiv:2603.06658. [cite: 3]
2 (Crítica	Integración de	En presencia	1 Día	Zhang, Y. et al.

Inmediata)	Regularización AEM (Maximización de la Entropía de Atención)	de ruido circundante (piel sana actuando como atajo de clasificación), la penalización entrópica global restringe a la red de colapsar la distribución de pesos sobre artefactos espaciales marginales, forzando una exploración integral de las características semánticas de la bolsa.	(Prototipable Mañana). Incorporación de un sumatorio logarítmico a la función de pérdida general (código fuente público disponible en GitHub, altamente eficiente en CPU). No requiere modificar la arquitectura de MobileNetV2.	(2025). <i>AEM: Attention Entropy Maximization for Multiple Instance Learning based Whole Slide Image Classification</i> . MICCAI 2025. [cite: 7, 8, 9]
3 (Medio Plazo)	Refactorización a FocusMIL (Inferencia Causal vía Max-Pooling + Cuello de Botella Variacional)	Abandona formalmente el paradigma de atención fallido. Evita el uso de la evidencia negativa (el ruido del relleno de las cajas delimitadoras diagonales) y enfoca a la red en la extracción puramente causal del tejido	Semanas. Requiere reescribir la etapa de agregación forward de la red para implementar el Max-Pooling junto con las funciones matemáticas del Cuello de Botella de Información Variacional y estabilización multi-bolsa.	Liu, X. et al. (2025). <i>From Correlation to Causation: Max-Pooling-Based Multi-Instance Learning Leads to More Robust Whole Slide Image Classification</i> . arXiv:2408.09449. [cite: 4, 6, 11]

		predominante, logrando la robustez extrema requerida en presencia de etiquetas inherentement e débiles.		
4 (Alternativa Técnica)	Agregación con QG-MIL Light	Sustituye el bloque Gated Attention por un módulo transformador ultraligero (2.4M de parámetros) optimizado con RMSNorm y SwiGLU, metodologías probadas de LLMs que previenen la concentración de atención y operan eficientemente en bolsas MIL de pequeño tamaño (decenas a cientos de instancias).	Semanas. Implica descartar la red de atención actual y realizar acoplamientos tensoriales para adaptar los vectores de características salientes de MobileNetV2 al nuevo módulo. Posible lentitud de entrenamiento iterativo en CPU.	<i>Zedda, L. et al. (2026). QG-MIL: A Gated Transformer Aggregator for Domain-Agnostic Multiple Instance Learning in Medical Imaging. arXiv:2606.20027. [cite: 5, 12, 13]</i>
5 (Descartado Expresamente)	Geo-MIL / Enfoques Basados en SAM2 sin Ajuste Fino	El modelado de grafos rompe la viabilidad técnica para la	N/A. Contraviene las restricciones estrictas del	<i>Huang, C. et al. (2026) / Bai et al. (2025). [cite: 20, 25]</i>

		exportación estática a entornos limitados por RAM (ONNX en Raspberry Pi). SAM2 <i>zero-shot</i> es estadísticamen te propenso a errores en dominios de bajo contraste dermatológico, lo que degradaría silenciosament e el terreno de verdad de la red.	proyecto en cuanto a hardware, capacidad de cómputo para ajuste y fidelidad de los datos de entrenamiento.	
--	--	--	--	--

Se aconseja que la investigación de mañana se centre exclusivamente en implementar las Opciones 1 y 2 simultáneamente. La sustitución analítica de la activación Softmax combinada con la regularización de la entropía de pérdida aborda los dos defectos matemáticos observados sin descartar el progreso ya logrado sobre la arquitectura.

8. Opinión Experta y Reestructuración Estratégica de la Defensa de la Tesis

Ante la interrogante final de si resulta razonable proyectar este enfoque débilmente supervisado como una mejora competitiva en la métrica cruda de segmentación (el coeficiente Dice) respecto al trabajo anterior completamente supervisado (el modelo ResUnet+Unet++ evaluado en más de 1000 imágenes), la respuesta empírica, clínica y estadística es: **Absolutamente no**. Y este no es un fallo del desarrollo; es una realidad fundamental de las ciencias computacionales modernas.

Superar un Dice del 78.6% empleando arquitecturas densas en servidores GPU requiere una resolución topológica a nivel de píxel inalcanzable a partir de 268 imágenes segmentadas mediante cajas delimitadoras con ruido intermedio, procesadas a través de redes ultraligeras en CPUs. La persecución exclusiva de métricas incrementales en segmentación es una trampa de evaluación clásica que oscurece el verdadero mérito de investigación de los sistemas embebidos en el ámbito de la salud³¹.

El proyecto requiere un reenmarcado urgente. La contribución sustancial y defendible de esta tesis de maestría no debe radicar en el delta de rendimiento métrico del modelo de visión, sino en su posicionamiento dentro de la **Frontera de Eficiencia de Pareto aplicada a la Inteligencia Artificial Clínica**.

El trabajo debe presentarse bajo el paradigma de **Diagnóstico Descentralizado y Optimización de Recursos** mediante la defensa de tres pilares arquitectónicos:

1. **Asimetría en los Costos de Anotación:** La anotación de contornos poligonales densos requerida para redes ResUnet consume centenares de horas especializadas, cuyo valor clínico marginal decae frente a la necesidad de diagnósticos rápidos de campo³². Demostrar que un sistema basado en MIL puede aprender localizaciones útiles a partir de ROIs generadas en una fracción del tiempo abre vías de implementación clínica que los modelos pesados simplemente no poseen.
2. **Viabilidad Embebida Real (Hardware-Aware AI):** El éxito del modelo radica en su limitación intencional. Mapear exitosamente un extractor MobileNetV2 y una capa de agregación estabilizada (ASMIL/AEM) a la memoria contenida y los ciclos de reloj limitados de una placa Raspberry Pi (con latencias del orden de 100 ms) justifica sacrificios marginales en el Dice en aras de construir una tecnología *Point-of-Care* verdaderamente desplegable¹⁶. Este punto de diseño se alinea con la vanguardia de la IA de borde (Edge AI) para países en vías de desarrollo³³.
3. **Localización como Indicador de Triage Clínico, no como Cuantificación Volumétrica:** La localización espacial defectuosa inicial se abordará para iluminar regiones clínicas sospechosas (mapas de calor interpretables de focos de isquemia o infección) dentro de la herida en lugar de delinear su geometría absoluta. Este cambio de objetivo metodológico transita de la "segmentación morfológica estricta" al "sistema de soporte de decisiones orientativo", un campo en rápida expansión en la IA médica de baja supervisión.

Al presentar el modelo final en la próxima reunión de revisión no como un competidor fallido de segmentación pesada, sino como un explorador pionero de compromisos (*trade-offs*) entre costo humano de etiquetado, restricciones extremas de infraestructura computacional e interpretabilidad visual clínica, el trabajo trasciende de un simple ejercicio de optimización de redes hacia una investigación rigurosa, defendible y con alto potencial de publicación en revistas de informática biomédica e ingeniería de sistemas hospitalarios.

Fuentes citadas

1. (PDF) Multi-Beholder: Biomarker Prediction for Low-Grade Glioma with Multiple Instance Learning and One-Class Classification - ResearchGate, https://www.researchgate.net/publication/404023670_Multi-Beholder_Biomarker_Prediction_for_Low-Grade_Glioma_with_Multiple_Instance_Learning_and_One-Class_Classification
2. SPECTRAL MULTIPLE-INSTANCE LEARNING FOR EFFICIENT GIGAPIXEL IMAGE ANALYSIS - OpenReview, <https://openreview.net/pdf/1f0a03814f63fe183c4842fbb1038413d3044570.pdf>

3. ASML: Attention-Stabilized Multiple Instance Learning for Whole Slide Imaging - arXiv, <https://arxiv.org/html/2603.06658v1>
4. Max-Pooling-Based Multi-Instance Learning Leads to More Robust Whole Slide Image Classification - arXiv, <https://arxiv.org/pdf/2408.09449>
5. QG-MIL: A Gated Transformer Aggregator for Domain-Agnostic Multiple Instance Learning in Medical Imaging - arXiv, <https://arxiv.org/html/2606.20027v1>
6. [2408.09449] From Correlation to Causation: Max-Pooling-Based Multi-Instance Learning Leads to More Robust Whole Slide Image Classification - arXiv, <https://arxiv.org/abs/2408.09449>
7. AEM: Attention Entropy Maximization for Multiple Instance Learning based Whole Slide Image Classification - GitHub, <https://github.com/dazhangyu123/AEM>
8. AEM: Attention Entropy Maximization for Multiple Instance Learning based Whole Slide Image Classification | MICCAI 2025, <https://papers.miccai.org/miccai-2025/0056-Paper5183.html>
9. AEM: Attention Entropy Maximization for Multiple Instance Learning based Whole Slide Image Classification - arXiv, <https://arxiv.org/pdf/2406.15303>
10. AEM: Attention Entropy Maximization for Multiple Instance Learning based Whole Slide Image Classification - arXiv, <https://arxiv.org/html/2406.15303v3>
11. From Correlation to Causation: Max-Pooling-Based Multi-Instance Learning Leads to More Robust Whole Slide Image Classification - arXiv, <https://arxiv.org/html/2408.09449>
12. [2606.20027] QG-MIL: A Gated Transformer Aggregator for Domain-Agnostic Multiple Instance Learning in Medical Imaging - arXiv, <https://arxiv.org/abs/2606.20027>
13. QG-MIL: A Gated Transformer Aggregator for Domain-Agnostic Multiple Instance Learning in Medical Imaging - ResearchGate, https://www.researchgate.net/publication/407287471_QG-MIL_A_Gated_Transformer_Aggregator_for_Domain-Agnostic_Multiple_Instance_Learning_in_Medical_Imaging
14. (PDF) Diabetic foot ulcer classification using an enhanced coordinate attention integrated ConvNext model - ResearchGate, https://www.researchgate.net/publication/399462211_Diabetic_foot_ulcer_classification_using_an_enhanced_coordinate_attention_integrated_ConvNext_model
15. (PDF) Advanced Classification of Diabetic Foot Ulcers Using Custom and Deep Learning Models - ResearchGate, https://www.researchgate.net/publication/394776804_Advanced_Classification_of_Diabetic_Foot_Ulcers_Using_Custom_and_Deep_Learning_Models
16. (PDF) Vision Transformer-based diabetic foot ulcer classification for mobile deployment: development, validation, and implementation of an iOS clinical decision support tool - ResearchGate, https://www.researchgate.net/publication/398546491_Vision_Transformer-based_diabetic_foot_ulcer_classification_for_mobile_deployment_development_validation_and_implementation_of_an_iOS_clinical_decision_support_tool
17. A clinically aligned multimodal workflow ... - Semantic Scholar, <https://pdfs.semanticscholar.org/c231/57db0d654c7a23de7fea70434affd5eca85b>

[pdf](#)

18. Using Segment Anything Model 2 for Zero-Shot 3D Segmentation of Abdominal Organs in Computed Tomography Scans to Adapt Video Tracking Capabilities for 3D Medical Imaging: Algorithm Development and Validation, <https://ai.jmir.org/2025/1/e72109/>
19. SAMRI-3D: Adapting SAM2 for 3D MRI Segmentation with Global Volume Tokens - arXiv, <https://arxiv.org/html/2607.18014v1>
20. Prompt SAM2 with Online Few-shot Learner for Efficient Medical Image Segmentation - arXiv, <https://arxiv.org/pdf/2512.24861>
21. Atlas is Your Perfect Context: One-Shot Customization for Generalizable Foundational Medical Image Segmentation - arXiv, <https://arxiv.org/html/2512.18176v2>
22. Comparing SAM 2 and SAM 3 for Zero-Shot Segmentation of 3D Medical Data - arXiv, <https://arxiv.org/html/2511.21926v2>
23. MedPixel: A Unified Pixel-Language Model for Medical Reasoning and Segmentation, <https://arxiv.org/html/2608.09818v1>
24. DFUGCN: Image Classifying Technique for Localizing of Diabetic Foot Ulcers, https://www.researchgate.net/publication/398714372_DFUGCN_Image_Classifying_Technique_for_Localizing_of_Diabetic_Foot_Ulcers
25. Geometric multi-instance learning for weakly supervised gastric cancer segmentation, https://www.researchgate.net/publication/399732492_Geometric_multi-instance_learning_for_weakly_supervised_gastric_cancer_segmentation
26. Inference Engineering | PDF | Artificial Intelligence - Scribd, <https://www.scribd.com/document/1003086483/Inference-Engineering>
27. MobileNetV2: A Computationally Efficient Model for Mango Leaf Disease Diagnosis: An Experimental Study - ResearchGate, https://www.researchgate.net/publication/398790022_MobileNetV2_A_Computationally_Efficient_Model_for_Mango_Leaf_Disease_Diagnosis_An_Experimental_Study
28. DBLA-MobileNetV2: Real-Time Rice Leaf Disease Detection on Edge Devices with Dual-Branch Lightweight Attention - ResearchGate, https://www.researchgate.net/publication/400638045_DBLA-MobileNetV2_Real-Time_Rice_Leaf_Disease_Detection_on_Edge_Devices_with_Dual-Branch_Lightweight_Attention
29. A Performance Analysis of You Only Look Once Models for Deployment on Constrained Computational Edge Devices in Drone Applications - MDPI, <https://www.mdpi.com/2079-9292/14/3/638>
30. (PDF) Optimization of MobileNet SSD Using Pruning, Quantization, and Transfer Learning for Real-Time Vehicle Detection in IoT-Based Security Systems - ResearchGate, https://www.researchgate.net/publication/404776639_Optimization_of_MobileNet_SSD_Using_Pruning_Quantization_and_Transfer_Learning_for_Real-Time_Vehicle_Detection_in_IoT-Based_Security_Systems
31. DermaFormer: an efficient foundation model for dermoscopic lesion segmentation

with mixed training strategies - SPIE Digital Library,
<https://www.spiedigitallibrary.org/conference-proceedings-of-spie/13930/139301N/DermaFormer--an-efficient-foundation-model-for-dermoscopic-lesion-segmentation/10.1117/12.3088032.full>

32. MS-CLAM – Mixed Supervision for Tumor Localization in WSIs,
<https://www.sop.inria.fr/members/Herve.Delingette/site/research/msclam/>
33. Building Automation Pipeline for Diagnostic Classification of Sporadic Odontogenic Keratocysts and Non-Keratocysts Using Whole,
<https://eprints.whiterose.ac.uk/id/eprint/207996/1/diagnostics-13-03384.pdf>