

**UNIVERSIDAD NACIONAL AUTÓNOMA DE
MÉXICO**

FACULTAD DE CIENCIAS

**IMPLEMENTACIÓN DEL ESQUEMA CO-MIL
PARA LA CLASIFICACIÓN DE ÚLCERAS DE PIE
DIABÉTICO**

**BITÁCORA DE INVESTIGACIÓN Y DISEÑO
ARQUITECTÓNICO**

QUE PARA OBTENER EL TÍTULO DE:

FÍSICO BIOMÉDICO

PRESENTA:

ADRIÁN EMILIANO BELTRÁN FERNÁNDEZ

TUTOR:

DR. JOSÉ EDUARDO CHAIREZ VELOZ

2026

Índice general

1. Introducción y Contexto Clínico-Computacional	2
2. Análisis Estructural y Selección del Backbone Homogeneizado	4
2.1. Evaluación del Rendimiento: MiT-b3 frente a MobileNetV2	4
2.2. Justificación de MobileNetV2 en el Paradigma Co-MIL	5
3. Fundamentos del Aprendizaje de Múltiples Instancias (MIL)	6
3.1. El Mecanismo de Pooling por Atención	6
4. Análisis de Datasets Clínicos y Dimensionamiento de Parches	8
4.1. La Paradoja de los 256x256 Píxeles	8
4.2. Estrategia de Manejo de Datasets	8
5. Flujo de Anotación Débil para MIL (Multi-Etiqueta)	10
5.1. El Proceso de Anotación	10
5.2. Mecanismo de Atención Multi-Etiqueta	10
6. Desecando la Arquitectura Co-MIL: El Flujo de Aprendizaje Continuo	11
7. Desarrollo, Entorno y Diseño de la Primera Arquitectura Funcional MIL	12

Capítulo 1

Introducción y Contexto Clínico-Computacional

Las complicaciones derivadas de la diabetes mellitus representan una de las cargas más críticas y financieramente exhaustivas para los sistemas de salud a nivel global [1, 2]. Entre estas complicaciones, las úlceras de pie diabético (UPD) se manifiestan como una de las secuelas más severas, estando directamente asociadas con un riesgo drásticamente elevado de infecciones crónicas, hospitalizaciones prolongadas y, en los casos de detección o tratamiento tardío, amputaciones de extremidades inferiores [2, 3]. La evaluación temprana, sistemática y precisa de estas lesiones resulta fundamental para orientar las decisiones clínicas, optimizar los recursos médicos y mejorar la calidad de vida del paciente [3]. En este contexto, la caracterización de los tejidos presentes en el lecho de la herida, tales como el tejido de granulación, la fibrina y el tejido calloso, proporciona indicadores visuales directos sobre la trayectoria de cicatrización o el deterioro de la úlcera [3].

Tradicionalmente, la evaluación de las úlceras de pie diabético ha dependido de la inspección visual clínica, un proceso inherentemente subjetivo y propenso a la variabilidad inter-observador [2, 3]. Con el advenimiento de la visión por computadora y el aprendizaje profundo (*Deep Learning*), la literatura ha presenciado un cambio de paradigma hacia la automatización del diagnóstico [2]. Las redes neuronales convolucionales (CNN) han demostrado una capacidad sin precedentes para extraer patrones complejos de imágenes médicas, superando en muchos casos la precisión del análisis humano [3]. Sin embargo, la aplicación de algoritmos de segmentación densa a nivel de píxel (como las arquitecturas U-Net estándar) enfrenta un obstáculo masivo en la práctica clínica real: la necesidad de conjuntos de datos exhaustivamente anotados por expertos médicos. Delinear con precisión los bordes de la fibrina o el tejido de granulación en miles de imágenes es una tarea laboriosa, costosa y, a menudo, impracticable para el desarrollo ágil de modelos a gran escala.

Para superar esta barrera de anotación, el paradigma del Aprendizaje de Múltiples Instancias (*Multiple Instance Learning*, MIL) se ha posicionado como la solución óptima en el análisis de imágenes médicas y patología computacional [2]. MIL es una forma de aprendizaje débilmente supervisado donde las etiquetas se asignan a conjuntos de datos, denominados “bolsas” (*bags*), en lugar de a instancias individuales [2]. En el contexto del pie diabético, una fotografía de la herida se divide en múltiples parches (instancias) que conforman la bolsa, y el diagnóstico (la etiqueta) se proporciona únicamente a nivel de la imagen global [3, 4].

No obstante, el despliegue de estos sistemas en entornos clínicos dinámicos, especialmente en dispositivos de bajo consumo como teléfonos móviles que son utilizados en unidades de atención primaria, introduce un desafío bidimensional [3]. Por un lado, el modelo debe ser computacionalmente eficiente. Por otro, el modelo debe ser capaz de aprender de manera continua a partir de nuevos flujos de datos de pacientes (nuevas variaciones de iluminación, tonos de piel, estadios de la úlcera) sin sufrir de “olvido catastrófico” (*catastrophic forgetting*), un fenómeno donde las redes neuronales sobrescriben abruptamente el conocimiento previo al ajustarse a nuevos dominios [1].

Esta convergencia de necesidades da origen al marco de trabajo **Co-MIL (Continual Multiple Instance Learning)**, el cual integra la eficiencia de la extracción de características, la interpretabilidad del pooling por atención y la robustez de las estrategias de aprendizaje continuo [3].

Capítulo 2

Análisis Estructural y Selección del Backbone Homogeneizado

El núcleo de cualquier arquitectura de visión por computadora, y particularmente de los modelos MIL, reside en su extractor de características o *backbone*. Este componente es el encargado de transformar el espacio de píxeles crudos de las imágenes médicas en un espacio latente de alta dimensionalidad, donde las características semánticas de la isquemia, la infección y los tipos de tejido se vuelven linealmente separables [3].

En la investigación preliminar [5], se llevó a cabo una evaluación exhaustiva de múltiples arquitecturas de segmentación utilizando el conjunto de datos DFUTissue. Una decisión metodológica de suma importancia destacada en dicho trabajo fue la homogeneización del rendimiento mediante la implementación de todos los backbones bajo la arquitectura U-Net. Esto asegura que cualquier discrepancia en el rendimiento provenga exclusivamente del codificador (*encoder*).

2.1. Evaluación del Rendimiento: MiT-b3 frente a MobileNetV2

La Tabla 2.1 proporciona un análisis comparativo crítico entre los modelos que demostraron el mejor desempeño.

Tabla 2.1: Comparativa de backbones en la tarea de análisis de tejidos (Adaptado de Maldonado, 2026 [5]).

Modelo Evaluado	Parámetros	Tamaño	Inf. CPU (s)	Inf. GPU (s)
Mejor Modelo (MiT-b3)	47.35 M	542.69 MB	> 0.9000	> 0.0300
Segundo Mejor (MobileNetV2)	6.63 M	76.31 MB	0.2505	0.0094

El modelo MiT-b3 se coronó como el modelo superior en términos de métricas de superposición. Sin embargo, requiere más de 47 millones de parámetros (542.69 MB). Para una

aplicación móvil orientada al diagnóstico en el punto de atención (*point-of-care*), cargar un modelo de este tamaño resultaría en un cuello de botella térmico y de memoria.

En contraste, el backbone MobileNetV2 [7] se erige como la elección maestra. Con apenas 6.63 millones de parámetros y 76.31 MB, representa una reducción del 85 % en los requisitos de almacenamiento, logrando procesar imágenes en 0.2505 s en una CPU y en 0.0094 s en una GPU [5].

2.2. Justificación de MobileNetV2 en el Paradigma Co-MIL

La sinergia entre MobileNetV2 y el paradigma Co-MIL radica en el manejo de la memoria RAM durante el proceso de aprendizaje continuo. Los esquemas de aprendizaje continuo basados en ensayo (*rehearsal*) requieren el mantenimiento de un búfer de memoria que almacena ejemplos representativos de datos pasados [1].

Al tener una huella minúscula, MobileNetV2 libera recursos de memoria RAM que pueden ser reasignados para incrementar el tamaño del búfer de repetición. Un búfer más grande se traduce directamente en una mitigación superior del olvido catastrófico. Por lo tanto, no es un sacrificio de precisión por velocidad, sino una optimización que hace posible la arquitectura Co-MIL en el borde (*Edge AI*).

Capítulo 3

Fundamentos del Aprendizaje de Múltiples Instancias (MIL)

El Aprendizaje de Múltiples Instancias (MIL) aborda el problema de la localización de patologías estructurando los datos en conjuntos [2]. Formalmente, una imagen clínica se subdivide en N parches. El conjunto completo conforma una bolsa $X = \{x_1, x_2, \dots, x_N\}$, donde cada x_i representa una instancia.

En la formulación clásica del problema MIL, solo la bolsa X posee una etiqueta observable $Y \in \{0, 1\}$. Las etiquetas individuales y_i son ocultas. El supuesto estándar se define como:

$$Y = \begin{cases} 1, & \text{si existe al menos un } i \text{ tal que } y_i = 1 \\ 0, & \text{si para todo } i, y_i = 0 \end{cases} \quad (3.1)$$

3.1. El Mecanismo de Pooling por Atención

La arquitectura de referencia en la literatura moderna, propuesta por Ilse et al. (2018) [6], introdujo el **Attention-based MIL (AB-MIL)**. Cada parche x_i se transforma en un vector latente $h_i = f_\theta(x_i)$. Posteriormente, el módulo de atención computa un peso α_i para cada instancia:

$$\alpha_i = \frac{\exp \{ \mathbf{w}^T \tanh(\mathbf{V} \mathbf{h}_i^T) \}}{\sum_{j=1}^N \exp \{ \mathbf{w}^T \tanh(\mathbf{V} \mathbf{h}_j^T) \}} \quad (3.2)$$

Frecuentemente se expande hacia un mecanismo de atención con compuertas (*Gated Attention*):

$$\alpha_i = \frac{\exp \{ \mathbf{w}^T (\tanh(\mathbf{V} \mathbf{h}_i^T) \odot \text{sigm}(\mathbf{U} \mathbf{h}_i^T)) \}}{\sum_{j=1}^N \exp \{ \mathbf{w}^T (\tanh(\mathbf{V} \mathbf{h}_j^T) \odot \text{sigm}(\mathbf{U} \mathbf{h}_j^T)) \}} \quad (3.3)$$

El vector representativo global de la bolsa completa, $\mathbf{z}$, se obtiene mediante la suma ponderada:

$$\mathbf{z} = \sum_{i=1}^N \alpha_i \mathbf{h}_i \tag{3.4}$$

Capítulo 4

Análisis de Datasets Clínicos y Dimensionamiento de Parches

Una de las discrepancias metodológicas más críticas reside en el manejo de las dimensiones de las imágenes entre el enfoque clásico de segmentación densa (U-Net) y el paradigma Co-MIL (basado en parches).

4.1. La Paradoja de los 256x256 Píxeles

En la tesis de referencia [5], se indica que las imágenes del **DFUTissue dataset** se homogeneizaron a una resolución fija de 256×256 píxeles mediante la técnica de *zero padding*. Esto se realizó porque arquitecturas como U-Net requieren que toda la imagen entre al modelo de una sola vez para devolver una máscara de segmentación píxel por píxel del mismo tamaño.

Sin embargo, el marco de trabajo MIL opera bajo un principio distinto: **la bolsa (*bag*) es la imagen completa, y las instancias son recortes (parches) extraídos de esa misma imagen de alta resolución.**

El tamaño de parche óptimo y recomendado en la literatura de dermatología computacional para modelos basados en CNN pre-entrenadas (como MobileNetV2) es de 224×224 píxeles o 256×256 píxeles. Esto significa que los parches *en sí mismos* deben tener esa resolución, recortados directamente de una imagen original de mayor tamaño.

4.2. Estrategia de Manejo de Datasets

Se cuenta con los siguientes conjuntos de datos, los cuales deben ser tratados considerando el paradigma basado en parches:

1. **DFUTissue:** Es necesario buscar las imágenes originales en alta resolución en el repositorio del proyecto PAPIIT para poder extraer los parches correctamente sin pérdida de contexto semántico.
2. **FUSeg / DFUC 2021:** Contienen imágenes en resoluciones más altas capturadas en entornos no controlados. Permiten aplicar una malla para extraer múltiples parches de 224×224 para generar bolsas robustas.

3. **Imágenes Propias (68 imágenes) y FENO (CUEC):** Deben ser capturadas en alta resolución (ej. 1080p). Se filtrará el fondo y se extraerá una cuadrícula de parches de 224×224 . Todos los parches de una sola foto formarán “la bolsa” del paciente.

Capítulo 5

Flujo de Anotación Débil para MIL (Multi-Etiqueta)

En el paradigma propuesto, **se anota la bolsa completa (la imagen global), no los parches individuales**. Dado que una sola úlcera puede presentar simultáneamente tejido de granulación, fibrina y callo, se utilizará el marco de **MIL Multi-Etiqueta** (*Multi-label MIL*).

5.1. El Proceso de Anotación

Para cada imagen clínica, se evaluará visualmente y se construirá un vector de presencia/ausencia para las tres clases. Por ejemplo:

- Úlcera con granulación y callo: $Y = [\text{Granulación} : 1, \text{Fibrina} : 0, \text{Callo} : 1]$.
- Úlcera con los tres tejidos: $Y = [\text{Granulación} : 1, \text{Fibrina} : 1, \text{Callo} : 1]$.

5.2. Mecanismo de Atención Multi-Etiqueta

La red no emite una sola probabilidad binaria, sino que genera **múltiples ramas de atención**, una por cada tipo de tejido ($\alpha_i^{\text{fibrina}}$, $\alpha_i^{\text{granulación}}$, α_i^{callo}). La función de pérdida castigará a la red si no logra encontrar al menos un parche que active fuertemente la atención para los tejidos marcados como positivos en la etiqueta global.

Capítulo 6

Desecando la Arquitectura Co-MIL: El Flujo de Aprendizaje Continuo

El esquema visualiza cómo el modelo procesa una imagen en tiempo real y se retroalimenta para aprender de nuevos pacientes.

- **1. Extracción de Parches:** La imagen se divide en parches de 224×224 píxeles, descartando el fondo.
- **2. Extractor de Características CNN:** Instanciado con **MobileNetV2** (como se discutió en el Capítulo 2), que comprime el contenido espacial en vectores densos.
- **3. Mecanismo de Pooling por Atención:** Aplica la ecuación de *Gated Attention* (Sección 3.1) de forma independiente para cada clase.
- **4. Cabezal de Clasificación:** Mapea la representación hacia las categorías clínicas.
- **5. Búfer de Repetición (Pseudo-Bolsas):** Extrae únicamente el subconjunto de instancias que recibieron los pesos de atención más altos. Estas “Pseudo-Bolsas” se almacenan en el búfer de repetición para el aprendizaje continuo, mitigando el olvido catastrófico al ser remuestreadas durante el *backpropagation* con nuevos pacientes [1].

Capítulo 7

Desarrollo, Entorno y Diseño de la Primera Arquitectura Funcional MIL

El lenguaje seleccionado es **Python** utilizando **PyTorch** como framework, dado su diseño dinámico (*Define-by-Run*) que permite manejar bolsas de longitud variable. El IDE será **VSCode** integrado con **GitHub**.

La primera arquitectura se diseñará bajo Programación Orientada a Objetos (POO):

1. **Módulo Extractor:** `mobilenet_v2` importado de `torchvision.models` (anulando el atributo `self.classifier`). Transformará cada parche de 224×224 en un tensor latente.
2. **Módulo de Atención (Multi-Label):** Implementación de capas lineales, tangentes hiperbólicas y sigmoides para emitir mapas de atención por clase, resultando en ponderaciones probabilísticas independientes para cada tejido.
3. **Módulo de Clasificación:** Multiplicación tensorial de la matriz de atención y la latente para condensar la información. Se utilizará la función de pérdida ***BCEWithLogitsLoss*** en lugar de *CrossEntropyLoss*, ya que BCE maneja adecuadamente la clasificación multi-etiqueta donde las clases no son mutuamente excluyentes.

Una vez confirmada la convergencia con *datasets proxies* o iniciales, se integrará el **Búfer de Repetición** para completar el paradigma Co-MIL.

Bibliografía

- [1] Kumari P., Chauhan J., Bozorgpour A., Huang B., Azad R., Merhof D. (2025). *Continual learning in medical image analysis: A comprehensive review of recent advancements and prospects*. Med Image Anal.
- [2] Barbosa D., Ferreira M., Braz G Jr., Salgado M., Cunha A. (2024). *Multiple instance learning in medical images: a systematic review*. IEEE Access.
- [3] Cassidy B., Kendrick C., Reeves ND., Pappachan JM., Yap MH. (2025). *Deep learning in chronic wound segmentation: a comprehensive review and meta-analysis*. Vis Comput.
- [4] Yap MH., Kendrick C., Cassidy B., et al. (2021). *Diabetic Foot Ulcers Grand Challenge 2021 (DFUC 2021)*. Zenodo.
- [5] Maldonado Ocica, A. J. (2026). *Evaluación de algoritmos de aprendizaje automatizado para el análisis de úlceras de pie diabético*. Tesina, Facultad de Ciencias, UNAM.
- [6] Ilse, M., Tomczak, J., & Welling, M. (2018). *Attention-based deep multiple instance learning*. International Conference on Machine Learning (ICML).
- [7] Sandler, M., Howard, A., Zhu, M., Zhmoginov, A., & Chen, L. C. (2018). *MobileNetV2: Inverted Residuals and Linear Bottlenecks*. CVPR.