

UNIVERSIDAD NACIONAL AUTÓNOMA DE MÉXICO

FACULTAD DE CIENCIAS

BITÁCORA DE INVESTIGACIÓN Y DISEÑO
ARQUITECTÓNICO

Implementación del esquema Co-MIL para la clasificación de úlceras de pie diabético

Proyecto de Práctica Profesional Supervisada

Alumno: Adrián Emiliano Beltrán Fernández

Tutor: Dr. José Eduardo Chairez Veloz

Ciudad de México, 2026

Índice general

Propósito del documento	iii
I Marco Teórico y Diseño Arquitectónico	1
1. Contexto Clínico-Computacional	2
2. Estado del Arte y Novedad del Enfoque	4
3. Análisis Estructural y Selección del Backbone	5
3.1. Evaluación: MiT-b3 frente a MobileNetV2	5
3.2. Justificación de MobileNetV2 en el paradigma Co-MIL	6
4. Fundamentos del Aprendizaje de Múltiples Instancias	7
4.1. El Mecanismo de Pooling por Atención	7
5. Resolución Adaptativa y Manejo de Datasets	9
5.1. La Paradoja de los 256x256 Píxeles	9
5.2. La Solución Innatamente Adaptativa del MIL	9
6. Flujo Multi-etiqueta y Arquitectura Co-MIL	11
6.1. Transición a MIL Multi-Etiqueta	11
6.2. Flujo Arquitectónico Co-MIL	12
6.3. Formalización Matemática del Framework MIML	13
II Registro de Desarrollo y Experimentación	15
7. Entorno de Desarrollo y Diseño de la Arquitectura Funcional	16
7.1. Diseño basado en Programación Orientada a Objetos (POO)	16
7.2. Construcción del Dataset MIL Sintético	17

7.3. Manejo Computacional de Bolsas de Longitud Variable	18
7.4. Entrenamiento y Función de Pérdida	18
7.5. Evaluación e Interpretabilidad: Mapas de Atención	18
8. Registro de Dudas y Decisiones (Bitácora Diaria)	20
9. Conclusiones Preliminares	29

Propósito del documento

El objetivo de esta bitácora no es solo registrar avances de codificación, sino dejar una trazabilidad rigurosa de las dudas, decisiones metodológicas, rectificaciones, hipótesis teóricas y justificaciones técnicas que guían la construcción del esquema Co-MIL para el análisis de úlceras de pie diabético.

La naturaleza de este documento es deliberadamente evolutiva: cada sección está pensada para escalar con nuevas observaciones, experimentos y lecturas. Por ello, se ha estructurado en dos grandes bloques: el primero consolida el marco teórico y las decisiones arquitectónicas firmes, mientras que el segundo opera como un registro dinámico del desarrollo experimental y la toma de decisiones diarias.

Parte I

Marco Teórico y Diseño Arquitectónico

Capítulo 1

Contexto Clínico-Computacional

Las complicaciones derivadas de la diabetes mellitus representan una de las cargas más críticas y financieramente exhaustivas para los sistemas de salud a nivel global [1, 2]. Entre estas complicaciones, las úlceras de pie diabético (UPD) se manifiestan como una de las secuelas más severas, estando directamente asociadas con un alto riesgo de infecciones crónicas, hospitalizaciones prolongadas y amputaciones de extremidades inferiores [3]. La evaluación temprana, sistemática y precisa de estas lesiones resulta fundamental para orientar las decisiones clínicas y mejorar la calidad de vida del paciente.

En este contexto, la caracterización de los tejidos presentes en el lecho de la herida, tales como el tejido de granulación, la fibrina y el tejido calloso, proporciona indicadores visuales directos sobre la trayectoria de cicatrización de la úlcera. Tradicionalmente, esta evaluación ha dependido de la inspección visual clínica, un proceso inherentemente subjetivo y propenso a la variabilidad inter-observador [2].

Con el advenimiento del aprendizaje profundo, las redes neuronales convolucionales han demostrado una capacidad notable para automatizar este diagnóstico. Sin embargo, la segmentación densa a nivel de píxel enfrenta un obstáculo masivo: la necesidad de conjuntos de datos exhaustivamente anotados. Delinear con precisión los bordes de la fibrina o del tejido de granulación en miles de imágenes es una tarea impracticable para el desarrollo ágil de modelos [4].

Para superar esta barrera de anotación, el paradigma del Aprendizaje de Múltiples Instancias (Multiple Instance Learning, MIL) se ha posicionado como una solución óptima [6]. MIL es una forma de aprendizaje débilmente supervisado donde las etiquetas diagnósticas se asignan a conjuntos de recortes de la imagen original, denominados “bolsas” (bags), en lugar de a píxeles individuales.

No obstante, el despliegue de estos sistemas en dispositivos móviles de unidades de atención primaria introduce un desafío crítico: el modelo debe aprender continuamente de nuevos

flujos de datos (nuevos pacientes, variaciones de luz) sin sufrir de *olvido catastrófico*, un fenómeno donde las redes sobrescriben abruptamente el conocimiento previo al ajustarse a nueva información [1]. Esta necesidad da origen al marco de trabajo Co-MIL (Continual Multiple Instance Learning) adaptado a entornos con recursos restringidos.

Capítulo 2

Estado del Arte y Novedad del Enfoque

La propuesta de un esquema Co-MIL multicapa para el análisis de úlceras de pie diabético surge como la hipótesis central de este proyecto. Es imperativo documentar su grado de novedad en la literatura científica.

Tras una revisión del estado del arte, se observa que el concepto de *Continual Multiple Instance Learning* emergió recientemente en la frontera de la patología computacional entre 2024 y 2025 [10, 12]. Estas publicaciones han introducido frameworks de Co-MIL, pero aplicados exclusivamente a Imágenes de Diapositiva Completa (Whole Slide Images, WSI) en entornos de histopatología y microscopía computacional de alta capacidad.

El grado de novedad de este proyecto de Práctica Profesional Supervisada radica en su **dominio de aplicación y restricciones de diseño**. Hasta la fecha, no existe registro de un algoritmo Co-MIL implementado para imágenes fotográficas macroscópicas de úlceras de pie diabético (visión por computadora de superficie), y mucho menos uno optimizado estructuralmente para su despliegue en dispositivos móviles mediante aprendizaje continuo en el borde (*Edge AI*).

Capítulo 3

Análisis Estructural y Selección del Backbone

El núcleo de cualquier arquitectura MIL reside en su extractor de características (*backbone*), encargado de transformar los píxeles crudos en un espacio latente de alta dimensionalidad donde los tejidos se vuelven linealmente separables.

3.1. Evaluación: MiT-b3 frente a MobileNetV2

En la investigación preliminar [9], se evaluaron múltiples arquitecturas utilizando el conjunto de datos DFUTissue, homogeneizando su rendimiento bajo la arquitectura U-Net.

Si bien los modelos basados en transformadores (como MiT-b3) demostraron superioridad en métricas teóricas, su inmensa carga paramétrica (más de 47 millones de parámetros y 542 MB) los hace inviables. Para una aplicación orientada al diagnóstico en el punto de atención, cargar un modelo de este tamaño resultaría en un cuello de botella térmico y de memoria.

Tabla 3.1: Comparativa de backbones en la tarea de análisis de tejidos [9]

Modelo	Parámetros	Tamaño	Inferencia (CPU / GPU)
MiT-b3	47.35 M	542.69 MB	> 0.9000 s / > 0.0300 s
MobileNetV2	6.63 M	76.31 MB	0.2505 s / 0.0094 s

3.2. Justificación de MobileNetV2 en el paradigma Co-MIL

En contraste, MobileNetV2 [7] ofrece una reducción drástica en los requisitos de cómputo. MobileNetV2, con apenas 6.63 millones de parámetros y 76.31 MB, representa una reducción del 85 % en los requisitos de almacenamiento, logrando procesar imágenes en 0.2505 s en una CPU y en 0.0094 s en una GPU [9].

La sinergia crítica entre MobileNetV2 y Co-MIL no es solo la velocidad, sino el manejo de la memoria RAM. Los esquemas de aprendizaje continuo basados en ensayo (*rehearsal*) requieren el mantenimiento de un búfer de memoria que almacena ejemplos representativos de pacientes pasados. Al tener una huella minúscula, MobileNetV2 libera recursos de RAM que pueden reasignarse para incrementar el tamaño de este búfer. Un búfer más grande se traduce en una retención superior del conocimiento previo, optimizando la estabilidad del sistema en dispositivos móviles.

Capítulo 4

Fundamentos del Aprendizaje de Múltiples Instancias

Formalmente, una imagen clínica se subdivide en N parches. El conjunto completo conforma una bolsa $X = \{x_1, x_2, \dots, x_N\}$, donde cada x_i representa una instancia. En la formulación clásica binaria de MIL, solo la bolsa X posee una etiqueta observable $Y \in \{0, 1\}$, mientras que las etiquetas individuales de los parches y_i permanecen ocultas.

4.1. El Mecanismo de Pooling por Atención

La arquitectura de referencia en la literatura moderna, propuesta por Ilse et al. (2018) [6], introdujo el *Attention-based MIL* (AB-MIL). A nivel intuitivo, este mecanismo funciona como un evaluador que escanea la imagen y le asigna una calificación de importancia.^a cada parche. Si un parche contiene tejido de granulación o fibrina, recibirá una calificación alta; si contiene la sábana del hospital o piel sana, su calificación tenderá a cero.

En lugar de promediar ciegamente toda la imagen (lo cual diluiría la información clínica), el sistema aprende a enfocar su capacidad computacional solo en las regiones relevantes. Matemáticamente, cada parche x_i se transforma en un vector latente $h_i = f_\theta(x_i)$ mediante la red neuronal. Posteriormente, el módulo de atención con compuertas (*Gated Attention*) computa un peso probabilístico α_i para cada instancia:

$$\alpha_i = \frac{\exp \left\{ w^T \left(\tanh \left(V h_i^T \right) \odot \sigma \left(U h_i^T \right) \right) \right\}}{\sum_{j=1}^N \exp \left\{ w^T \left(\tanh \left(V h_j^T \right) \odot \sigma \left(U h_j^T \right) \right) \right\}} \quad (4.1)$$

Desglosando esta formulación para comprender su comportamiento dinámico:

- h_i : Representa el resumen matemático (vector latente) que el *backbone* extrajo del parche

i.

- V y U : Son matrices de pesos aprendibles. Su función es proyectar las características del parche a un espacio donde la red pueda evaluar su relevancia clínica.
- $\tanh$: Esta función de activación captura las características complejas y no lineales del tejido.
- σ (Sigmoides): Actúa como la compuerta" (*Gate*). Su trabajo es filtrar el ruido de fondo; si un parche carece de información útil clínica, la sigmoide arroja un valor cercano a 0, atenuando la activación de la rama $\tanh$.
- w^T : Es el vector final que proyecta las matrices a un valor escalar único (el peso de atención bruto).
- El denominador: Es una función *Softmax* que normaliza los pesos para que la suma de todos los α_i en la bolsa sea exactamente 1, convirtiéndolos en una distribución de probabilidad espacial.

El vector representativo global de la bolsa completa, z , se obtiene mediante la suma ponderada de todas las instancias, permitiendo que el diagnóstico final se base únicamente en los parches más informativos:

$$z = \sum_{i=1}^N \alpha_i h_i \quad (4.2)$$

Capítulo 5

Resolución Adaptativa y Manejo de Datasets

En enfoques de visión por computadora clásicos, la red exige una entrada de tensor fija (ej. $1 \times 3 \times 224 \times 224$). Si un paciente sube una fotografía en 4K, el sistema se ve obligado a comprimir la imagen, destruyendo irremediabilmente los detalles microscópicos de los tejidos de la herida.

5.1. La Paradoja de los 256x256 Píxeles

Este problema es evidente en datasets públicos como el DFUTissue [8], donde las imágenes originales fueron estandarizadas a una resolución artificial de 256×256 mediante *zero padding*. Extraer sub-parches de imágenes que ya fueron severamente comprimidas destruiría el contexto semántico. Por ello, para este proyecto es imperativo acudir a repositorios en crudo o capturar imágenes propias en alta resolución (como las obtenidas en colaboración con la FENO).

5.2. La Solución Innatamente Adaptativa del MIL

La ventaja arquitectónica de MIL es que la adaptación a la resolución de entrada ocurre en la dinámica de la extracción de la bolsa, operando bajo las siguientes reglas:

1. El tamaño del parche (instancia) será constante: 224×224 píxeles (óptimo para MobileNetV2).
2. La imagen original del paciente (sea 4K o 1080p) **no se redimensiona**.

3. Se aplica un algoritmo de cuadrícula deslizante (*Sliding Window*) sobre la imagen original para extraer los recortes y se descarta el fondo inútil.

Como resultado, si el paciente sube una imagen de alta calidad, se generará una bolsa masiva (ej. $N = 250$ parches). Si es de baja resolución, la bolsa será pequeña ($N = 12$). Dado que el mecanismo de atención realiza una suma ponderada, la red neuronal es matemáticamente agnóstica a la cantidad de parches N , preservando la fidelidad óptica al 100 %.

Capítulo 6

Flujo Multi-etiqueta y Arquitectura Co-MIL

6.1. Transición a MIL Multi-Etiqueta

Dado que una sola úlcera puede presentar simultáneamente tejido de granulación, fibrina y callo en distintas proporciones, la formulación binaria es insuficiente. En el flujo de trabajo propuesto, el clínico realiza una anotación débil global indicando la presencia concurrente de los tejidos. Por ejemplo, una úlcera con los tres tejidos genera el vector $Y = [1, 1, 1]$.

El modelo no emite una sola probabilidad, sino que ramifica su mecanismo de atención para buscar independientemente cada tejido: $\alpha_i^{\text{fibrina}}$, $\alpha_i^{\text{granulación}}$, α_i^{callo} . Para converger correctamente, se empleará la función de pérdida `BCEWithLogitsLoss`, diseñada específicamente para clases que no son mutuamente excluyentes.

6.2. Flujo Arquitectónico Co-MIL

Arquitectura Co-MIL: Flujo de Aprendizaje de Múltiples Instancias Continuo




Figura 6.1: Primer diagrama de referencia de la arquitectura CO-MIL

Como se ilustra en el diagrama de arquitectura, el ciclo de vida del procesamiento de una imagen clínica opera bajo un flujo continuo y adaptativo:

1. **Extracción Dinámica (Creación de Bolsas):** La imagen de entrada es procesada (idealmente tras un filtrado de región de interés basado en segmentación previa) mediante una cuadrícula espacial, generando una bolsa X compuesta por N parches de 224×224 píxeles.
2. **Extractor de Características CNN:** Cada uno de los N parches es alimentado independientemente a través del *backbone* (MobileNetV2), el cual comprime el espacio de píxeles en tensores latentes densos.
3. **Mecanismo de Pooling por Atención:** Los tensores individuales entran al módulo de atención, el cual calcula dinámicamente el nivel de relevancia de cada parche. Al realizar una suma ponderada, el módulo colapsa los N vectores en una única representación global de la bolsa, siendo matemáticamente agnóstico a la cantidad de parches iniciales.
4. **Cabezal de Clasificación Multi-Etiqueta:** La representación global se bifurca en ramas de predicción independientes (Granulación, Fibrina, Calloso), optimizadas mediante la función de pérdida `BCEWithLogitsLoss`.

5. **Retroalimentación y Aprendizaje Continuo:** Simultáneamente a la clasificación, el sistema extrae las *Pseudo-Bolsas* (el subconjunto de parches que recibieron los pesos de atención más altos) y las almacena en un Búfer de Repetición. Estos representantes históricos se remuestrearán en ciclos de entrenamiento futuros para consolidar el conocimiento y evitar el olvido catastrófico de dominios de pacientes previos.

6.3. Formalización Matemática del Framework MIML

Para abordar la complejidad inherente de las úlceras de pie diabético, este proyecto adopta formalmente el marco de trabajo de Aprendizaje Multinstancias y Multietiqueta (MIML) propuesto por Zhou et al.[cite: 414, 449]. En los marcos de aprendizaje tradicionales, un objeto se asocia a un único concepto y se representa mediante una sola instancia de características[cite: 428, 432]. Sin embargo, el lecho de una herida es un objeto semánticamente complejo que presenta ambigüedad tanto en el espacio de entrada (múltiples parches visuales o instancias) como en el espacio de salida (múltiples tipos de tejidos coexistentes o etiquetas)[cite: 580, 581, 582]. El marco MIML resulta ser la aproximación más natural y conveniente para modelar tareas que involucran este nivel de ambigüedad[cite: 584].

Bajo la representación MIML, una imagen clínica completa se define como un ejemplo descrito por múltiples instancias y asociado a múltiples etiquetas simultáneamente[cite: 418]. Matemáticamente, la tarea general consiste en aprender una función $f : 2^{\mathcal{X}} \rightarrow 2^{\mathcal{Y}}$ a partir de un conjunto de datos de entrenamiento $\{(X_1, Y_1), (X_2, Y_2), \dots, (X_m, Y_m)\}$ [cite: 568]. En este contexto, $X_i \subseteq \mathcal{X}$ es un conjunto de instancias $\{x_{i1}, x_{i2}, \dots, x_{i,n_i}\}$ que corresponden a los parches extraídos de la herida, y $Y_i \subseteq \mathcal{Y}$ es un subconjunto de etiquetas $\{y_{i1}, y_{i2}, \dots, y_{i,l_i}\}$ que indican los tejidos presentes (ej. granulación, fibrina, callo)[cite: 568].

Para resolver computacionalmente este problema, la arquitectura Co-MIL propuesta en este proyecto aplica una estrategia de degeneración, utilizando el aprendizaje multietiqueta como puente lógico[cite: 628, 629]. El proceso de *pooling* por atención transforma la bolsa dinámica de instancias X_i en un vector representativo global de dimensionalidad fija, mapeando efectivamente el problema hacia una tarea de aprendizaje multietiqueta estándar $f_{MLL} : \mathcal{Z} \rightarrow 2^{\mathcal{Y}}$ [cite: 629]. Finalmente, esta tarea se resuelve mediante el cabezal de clasificación empleando `BCEWithLogitsLoss`, lo que en la práctica descompone el problema multietiqueta en múltiples problemas de clasificación binaria independientes (uno por cada clase de tejido)[cite: 631, 697].

Finalmente, es importante destacar que la métrica tradicional de exactitud (*accuracy*) pierde gran parte de su significado bajo este paradigma, ya que evaluar clasificaciones parcialmente correctas requiere un análisis más profundo[cite: 704, 706]. Por ello, el desempeño

del modelo se evaluará utilizando criterios específicos para problemas con múltiples etiquetas, tales como la pérdida de Hamming (*Hamming loss*), el error superior (*one-error*), la cobertura (*coverage*) y la precisión promedio (*average precision*)[cite: 708, 709].

Parte II

Registro de Desarrollo y Experimentación

Capítulo 7

Entorno de Desarrollo y Diseño de la Arquitectura Funcional

El desarrollo computacional del proyecto se realiza en lenguaje Python utilizando PyTorch como *framework* principal. Esta elección se fundamenta en su grafo computacional dinámico (*Define-by-Run*), el cual es un requisito arquitectónico innegociable para manejar "bolsas" de longitud variable (donde cada paciente puede generar desde 15 hasta más de 200 parches).

Adicionalmente, el entorno se robustece con la integración de la librería especializada `torchmil` [11] para el manejo estandarizado de operaciones de Aprendizaje Multinstancia, y `tensordict` para la manipulación estructurada de lotes de datos complejos. El desarrollo de codificación y control de versiones se gestiona mediante VSCode integrado con GitHub.

7.1. Diseño basado en Programación Orientada a Objetos (POO)

Para garantizar la escalabilidad, mantenibilidad y la futura integración del búfer de repetición (vital para el esquema Co-MIL), la arquitectura se diseñó estrictamente bajo el paradigma de Programación Orientada a Objetos. Todos los bloques estructurales heredan de la clase base `torch.nn.Module`.

El diseño abstrae la red en tres módulos principales y desacoplados:

1. **Módulo Extractor a Nivel de Instancia (*Instance Encoder*):** Esta clase se encarga de procesar cada parche de forma individual. En la fase de despliegue clínico, instanciará el modelo `mobilenet_v2` (importado de `torchvision.models`), anulando su atributo `classifier` para utilizarlo exclusivamente como un generador de vectores latentes (*embeddings*) espaciales.

2. **Módulo Agregador de Atención (*Attention Aggregator*):** Es el núcleo del sistema MIL. Se implementa como una clase que define internamente las capas lineales, tangentes hiperbólicas y funciones sigmoideas necesarias para ejecutar la ecuación del *Gated Attention*. Su función es recibir el tensor de la bolsa completa, emitir los pesos de atención probabilísticos α_i (ignorando el *padding* mediante máscaras booleanas) y devolver un único vector global que resume la patología.
3. **Módulo Clasificador a Nivel de Bolsa (*Bag Classifier*):** Una clase compuesta por un Perceptrón Multicapa (MLP) que recibe el vector global condensado por el módulo de atención. Ejecuta la transformación matemática final para mapear la información hacia las clases clínicas objetivo, entregando los *logits* que serán evaluados por la función de pérdida `BCEWithLogitsLoss` para la clasificación multi-etiqueta.

Esta separación modular es crucial: permite que durante las fases tempranas de desarrollo se pueda sustituir el pesado extractor de imágenes por un extractor de vectores simples (como se hará en las pruebas con el dataset proxy MNIST), manteniendo intacta la lógica de atención y clasificación.

7.2. Construcción del Dataset MIL Sintético

En el paradigma MIL, se asume que una bolsa es positiva (clase 1) si al menos una de sus instancias es positiva, y negativa (clase 0) solo si la totalidad de sus instancias son negativas. Matemáticamente, esto se modela extrayendo el valor máximo de las etiquetas de las instancias: $Y = \max\{y_1, \dots, y_n\}$.

Para el experimento base, se aplanaron las imágenes de 28×28 píxeles del conjunto MNIST en vectores de 784 dimensiones y se normalizaron. Utilizando el módulo `ToyDataset`, se generaron bolsas dinámicas con tamaños aleatorios de entre 7 y 12 instancias ($N \in [7, 12]$). Se definió como criterio de positividad que la bolsa contuviera al menos un dígito “0” o “1” (`obj_labels = [0, 1]`).

Estructuralmente, cada bolsa se almacenó como un objeto `TensorDict` de PyTorch, encapsulando:

- **X:** La matriz de características de las instancias.
- **Y:** La etiqueta global de la bolsa (observable por la red).
- **y_inst:** Las etiquetas individuales de las instancias (estrictamente ocultas durante el entrenamiento y reservadas solo para métricas de validación final).

7.3. Manejo Computacional de Bolsas de Longitud Variable

Uno de los desafíos técnicos de MIL es la construcción de mini-lotes (*mini-batches*) eficientes para la GPU cuando cada bolsa X_i tiene una cantidad N distinta de instancias.

En lugar de utilizar tensores anidados (`torch.nested`, aún en fase de prototipo en PyTorch), se resolvió el problema de dimensionalidad aplicando una función de *padding* dinámico (`collate_fn`). El *DataLoader* agrupa 32 bolsas por iteración, rellenando con tensores de ceros aquellas bolsas más pequeñas hasta igualar el tamaño de la bolsa más grande del lote.

Para evitar que el modelo asigne pesos de atención al “relleno”, el dataloader emite un tensor booleano adicional (`mask`) que indica qué instancias son reales y cuáles son artificiales, permitiendo al mecanismo de atención anular matemáticamente el *padding*.

7.4. Entrenamiento y Función de Pérdida

Se instanció un modelo basado en el *Attention-Based MIL* (AB-MIL) con una dimensión de *embedding* de 256 y una dimensión de atención de 128.

El modelo fue optimizado mediante el algoritmo Adam (*Learning Rate* de 0.005) durante 20 épocas. En congruencia con la justificación arquitectónica del Capítulo 6, la retropropagación del error se calculó utilizando la función `BCEWithLogitsLoss`.

Los registros de entrenamiento mostraron una convergencia altamente estable, pasando de una pérdida (*loss*) inicial de 0,093 a 0,030 en la época 20, y logrando una exactitud (*accuracy*) superior al 99 % en la predicción global de las bolsas.

7.5. Evaluación e Interpretabilidad: Mapas de Atención

El verdadero poder predictivo del esquema MIL no radica únicamente en predecir si la bolsa es positiva, sino en su capacidad inherente para localizar **dónde** reside la positividad sin haber recibido anotaciones a nivel de instancia.

Para evaluar esta interpretabilidad, se extrajeron los vectores de atención crudos (`att`) emitidos por el modelo y se normalizaron excluyendo los valores enmascarados por el *padding*. Al superponer una máscara visual (mapa de calor) proporcional al peso de atención de cada parche, se observó que la red asignaba un α_i cercano a 1,0 exclusivamente a las instancias que contenían los dígitos “0” o “1”, asignando valores ínfimos al resto de los números.

Las métricas a nivel de instancia confirmaron este hallazgo visual: el modelo logró un *F1-Score* de instancia de 0,916 y una precisión de 0,980. Esto valida la hipótesis metodológica del proyecto: el *Gated Attention* es capaz de enfocar su capacidad computacional en los parches relevantes (la “patología”) filtrando el ruido de fondo, de forma puramente débilmente supervisada.

Capítulo 8

Registro de Dudas y Decisiones (Bitácora Diaria)

Esta sección está destinada al registro cronológico del progreso. (Se añadirá contenido iterativamente durante el periodo de Práctica Profesional Supervisada).

Plantilla de Ingreso

Fecha:

Contexto/Duda:

Análisis y Pruebas:

Decisión Arquitectónica:

Dimensionamiento de Bolsas y Resoluciones Móviles

Fecha: [1 de Marzo de 2026]

Contexto/Duda: En el contexto de MIL, si los pacientes suben imágenes con resoluciones muy variables (desde celulares antiguos hasta gama alta), ¿cuántas instancias de 224×224 se generarán por bolsa y cómo impactará esto en la memoria de la GPU?

Análisis y Pruebas: Para calcular el número total de parches (N) sin solapamiento ($stride = 224$), se utilizó la fórmula basada en la división entera:

$$N = \left\lfloor \frac{\text{Ancho}_{\text{imagen}}}{224} \right\rfloor \times \left\lfloor \frac{\text{Alto}_{\text{imagen}}}{224} \right\rfloor$$

Se calculó la siguiente tabla comparativa de escenarios reales:

Generación de Cámara	Resolución Típica	Cálculo (Grilla)	Total Parches
Gama Baja Antigua	640 × 480 (VGA)	2 × 2	4
Dispositivos Legacy	1600 × 1200 (2 MP)	7 × 5	35
Estándar Actual	4032 × 3024 (12 MP)	18 × 13	234
Premium (Ultra-Res)	12000 × 9000 (108 MP)	53 × 40	2120

Decisión Arquitectónica: El cálculo demostró que un sensor moderno de 108 MP generaría más de 2,100 instancias. Esto justifica y reafirma la decisión de utilizar **MobileNetV2** como *backbone*. Usar modelos masivos (como ViT o ResNet) provocaría un desbordamiento de memoria (OOM). Además, dado que la operación *floor* descarta píxeles residuales, la implementación del código deberá aplicar *zero-padding* al perímetro de la imagen original para no perder información si la úlcera toca los bordes del encuadre.

Optimización del Sliding Window mediante Segmentación Previa

Fecha: [5 de Marzo de 2026]

Contexto/Duda: El algoritmo de *Sliding Window* propuesto extrae parches de 224×224 de forma ciega por toda la imagen. Esto genera cientos de parches inútiles (fondo, sábanas, piel sana). Surgió la duda: ¿Se puede usar el modelo de segmentación de la tesina anterior para recortar el fondo antes de crear la bolsa? ¿Esto sacrificaría píxeles valiosos en fotos de baja calidad o rompería la filosofía de aprendizaje débilmente supervisado de Co-MIL?

Análisis y Pruebas: Se analizó el impacto técnico de aislar la Región de Interés (ROI). Aislar la herida **no disminuye la resolución intrínseca** de la misma; únicamente descarta los píxeles de ruido. Por ejemplo, en una foto VGA (640×480), si la úlcera solo ocupa 250×250 píxeles, procesar el fondo completo diluye la atención. Al usar una máscara de segmentación previa, extraemos una caja delimitadora (*Bounding Box*) que envuelve solo los píxeles positivos de la úlcera, incrementando dramáticamente la relación señal/ruido.

Asimismo, se concluyó que esto no rompe el paradigma MIL. Co-MIL está diseñado para resolver la clasificación multi-etiqueta a nivel de tejidos microscópicos (granulación, fibrina, callo) sin máscaras manuales. Usar un modelo externo únicamente como un "localizador macroscópico" de la herida es una modularización válida.

Decisión Arquitectónica: Se modificará el flujo (pipeline) de inferencia a dos etapas:

1. **Detección (ROI):** La imagen cruda pasa por el modelo U-Net de la tesina, generando una máscara binarizada y extrayendo las coordenadas extremas del *Bounding Box*.

2. **Extracción Co-MIL:** El *Sliding Window* se ejecuta exclusivamente dentro del *Bounding Box*, generando una bolsa (N) mucho más pequeña, limpia y con un altísimo valor clínico para el módulo de atención.

Entrada: Evolución hacia Segmentación Semántica Débilmente Supervisada (WSSS)

Fecha: [28 de Marzo del 2026]

Contexto del Problema: Los requerimientos clínicos establecidos por la Facultad de Enfermería (FENO) exigen la cuantificación morfométrica exacta del lecho de la herida, específicamente el área en cm^2 de cada tejido individual (granulación, fibrina, callo). Para la calibración espacial, se utiliza un marcador fiduciario (ArUco) de 2×2 cm en el campo visual.

Esto introduce una tensión arquitectónica: el marco Co-MIL opera bajo el paradigma de *Multiple Instance Learning*, el cual emite diagnósticos a nivel de bolsa y mapas de atención a nivel de parche (224×224 píxeles). Proyectar estos mapas de atención genera una cuadrícula de resolución gruesa, la cual es matemáticamente insuficiente para calcular el área de fronteras orgánicas y asimétricas requeridas en la práctica clínica. Abandonar Co-MIL por un modelo de segmentación densa (como U-Net multiclase) resultaría inviable, ya que exigiría la anotación manual exhaustiva (píxel por píxel) de miles de imágenes por parte de expertos médicos.

Resolución Arquitectónica: El Pipeline Híbrido y la Formulación CRF

Para satisfacer la necesidad de precisión nanométrica sin sacrificar las ventajas del aprendizaje débilmente supervisado, se determinó evolucionar la arquitectura hacia un esquema de *Weakly Supervised Semantic Segmentation* (WSSS). El sistema abandona la idea de un algoritmo único.^{en} favor de una tubería de procesamiento modular:

1. **Calibración Espacial:** Algoritmos de visión clásica (OpenCV) detectan el marcador ArUco, extraen el factor de conversión (píxeles a cm^2) y enmascaran el marcador con ceros para evitar interferencias en la red neuronal.
2. **Macrolocalización:** Se utiliza la inferencia de un modelo U-Net base (desarrollado en etapas previas) para aislar la Región de Interés (ROI) y calcular el área total macroscópica.
3. **Atención Débil (Co-MIL):** El modelo procesa la bolsa extraída de la ROI y genera Mapas de Activación de Clase (CAMs) gruesos basados en los pesos probabilísticos α_i para cada tejido.

4. Refinamiento Denso mediante Campos Aleatorios Condicionales (DenseCRF):

Para transformar la atención gruesa de Co-MIL en una máscara de píxeles exacta, se implementa un modelo de *Conditional Random Field* totalmente conectado. El CRF modela la segmentación como un problema de minimización de energía. Para una asignación de etiquetas x , la energía del sistema se define como:

$$E(x) = \sum_i \psi_u(x_i) + \sum_{i < j} \psi_p(x_i, x_j) \quad (8.1)$$

Donde:

- **Potencial Unario (ψ_u):** Representa el costo inicial de asignar una etiqueta al píxel i . Este valor se inicializa directamente utilizando los pesos probabilísticos espaciales (α_i) generados por el mapa de atención del modelo Co-MIL.
- **Potencial Binario (ψ_p):** Actúa como el regularizador espacial y de contraste. Evalúa pares de píxeles i y j , penalizando asignaciones de etiquetas distintas si los píxeles tienen colores (RGB) muy similares y están físicamente cerca. Se define mediante núcleos gaussianos:

$$\psi_p(x_i, x_j) = \mu(x_i, x_j) \left[w_1 \exp \left(-\frac{|p_i - p_j|^2}{2\theta_\alpha^2} - \frac{|I_i - I_j|^2}{2\theta_\beta^2} \right) + w_2 \exp \left(-\frac{|p_i - p_j|^2}{2\theta_\gamma^2} \right) \right] \quad (8.2)$$

Aquí, p_i y p_j son las posiciones espaciales, mientras que I_i e I_j son los vectores de intensidad de color.

Impacto del Post-procesamiento CRF: Al minimizar iterativamente esta función de energía, el CRF fuerza a que los bloques cuadrados de atención generados por Co-MIL se "derritan" y se adhieran a los gradientes visuales naturales de la imagen (los bordes reales de la fibrina o granulación delineados por el cambio de color). Las áreas en cm^2 de cada tejido se derivan finalmente contando los píxeles de esta pseudo-máscara refinada y multiplicándolos por el ratio del ArUco, satisfaciendo así el requisito clínico con alta rigurosidad matemática y manteniendo el costo de anotación médica en cero.

Entrada: Recepción de lote de imágenes de úlceras en alta resolución

Fecha: [6 de Abril del 2026]

Contexto del Problema: Recepción del primer lote de datos reales (268 imágenes de alta

resolución). Las imágenes presentan una variabilidad extrema en sus dimensiones métricas (ej. 4032x3024, 2592x1944, 2268x4032) y en la orientación anatómica del pie. La duda central es cómo estandarizar la generación de las bolsas de instancias dinámicas bajo el paradigma MIL sin distorsionar la relación de aspecto ni agotar la memoria disponible al procesar resoluciones masivas.

Análisis y Pruebas: Se evaluó el impacto de las resoluciones variables utilizando la formulación de cuadrícula espacial previamente establecida: $N = \lfloor \frac{Ancho_{imagen}}{224} \rfloor \times \lfloor \frac{Alto_{imagen}}{224} \rfloor$. Al inyectar las dimensiones reales del nuevo dataset, observamos las siguientes variaciones en la longitud de la bolsa (N):

Para 4032x3024 px: $18 \times 13 = 234$ instancias por bolsa. Para 2592x1944 px: $11 \times 8 = 88$ instancias por bolsa. Para orientaciones verticales (2268x4032 px): $10 \times 18 = 180$ instancias por bolsa. Esta variabilidad confirma dos fenómenos arquitectónicos.

Primero, la orientación anatómica del pie (horizontal vs. vertical) es irrelevante para el modelo, ya que el mecanismo de pooling por atención es matemáticamente agnóstico a la estructura espacial original tras aplanar la cuadrícula. Segundo, procesar a ciegas resoluciones de 4032x3024 px generaría hasta 234 parches, de los cuales una inmensa mayoría correspondería a ruido de fondo, diluyendo drásticamente la capacidad de atención. **Decisión Arquitectónica:** Para la validación inicial (MVP) del modelo Co-MIL, se suspenderá temporalmente la inferencia automática de la etapa U-Net para macrolocalización. En su lugar, se desarrollará un software de preprocesamiento interactivo que permita al usuario humano: Trazar una caja delimitadora (Bounding Box) manual sobre la úlcera para aislar la Región de Interés (ROI). Aplicar una anotación débil global a nivel de bolsa indicando la presencia del tejido de granulación, fibrina y callo. Ejecutar el algoritmo de Sliding Window exclusivamente dentro de este recorte, aplicando zero-padding en los bordes para retener los píxeles residuales. Esta estrategia intermedia aislará el rendimiento del mecanismo de atención puro, permitiendo evaluar si el paradigma Co-MIL es viable antes de automatizar por completo el pipeline de segmentación.

Extracción Inteligente de Bolsas, Reflection Padding y Mitigación de Sesgo MIML

Fecha: [6 de Abril de 2026]

Contexto/Duda: Tras analizar el primer lote de imágenes clínicas en alta resolución, surgieron dos problemas arquitectónicos críticos para la transición de píxeles a tensores MIL:

- 1) La función estándar de extracción de parches (Sliding Window) recorta rígidamente cuadros

de 224×224 px. Si la región de interés (ROI) no es un múltiplo exacto, el método convencional emplea *Zero-Padding*, lo cual introduce bordes negros artificiales que corrompen la extracción de gradientes de la red convolucional (MobileNet V2). 2) A nivel diagnóstico, la inmensa mayoría de las úlceras crónicas presentan simultáneamente los tres tejidos, generando siempre un vector $Y = [1, 1, 1]$. Esto amenaza con inducir el síndrome de la red perezosa" (colapso de varianza), donde el modelo deja de optimizar los pesos del *Gated Attention* al asumir una positividad universal.



Figura 8.1: Ejemplo de imagen en alta resolución (4032x3024 px)

Análisis y Pruebas: Para el primer problema, se descartó la interpolación geométrica (redimensionar la imagen) para no violar la "Paradoja de los 256x256 píxeles", ya que alteraría la escala óptica para la futura cuantificación en cm^2 . En su lugar, se analizó el uso de expansión de contexto y *Reflection Padding*. Al usar un efecto espejo en los bordes físicos de la fotografía, se mantiene una derivada matemática continua, permitiendo a los filtros convolucionales procesar la imagen sin detectar "bordes geométricos" falsos. Para el segundo problema, se curó manualmente un subconjunto de casos raros" (ej. dehiscencias quirúrgicas puras con vectores $[1, 1, 0]$ o muñones de amputación limpios $[1, 0, 0]$) para forzar al modelo a aislar las características independientes de cada tejido.

Decisión Arquitectónica: Se construyó y validó un software intermedio de preprocesamiento interactivo. El sistema aplica una "expansión Inteligente" simétrica del *Bounding Box*

para absorber tejido biológico real (el cual será posteriormente filtrado por el mecanismo de atención al considerarlo fondo inútil). El producto final estandarizado es un archivo .pt que contiene un diccionario con la Bolsa X (un tensor de dimensiones $[N, 3, 224, 224]$) y el vector de etiquetas Y . El siguiente paso procedimental es la construcción del `DataLoader` y la función `collate_fn` para ensamblar estas bolsas dinámicas en mini-lotes manejables por la GPU.




Figura 8.2: Me falta descripción de la imagen

Validación del Flujo Tensorial y Padding Dinámico en PyTorch

Fecha: 8 de Abril de 2026

Contexto/Duda: Antes de comprometer recursos computacionales en el entrenamiento de la red con el dataset completo, era imperativo validar que la arquitectura orientada a objetos (POO) fuera capaz de ensamblar mini-lotes (mini-batches) con bolsas de tamaño variable sin generar desbordamientos de memoria ni errores de dimensionalidad.

Análisis y Pruebas: Se implementó un script de validación inicial (MVP) utilizando un subconjunto de 5 bolsas procesadas. El `DataLoader` agrupó exitosamente lotes de tamaño 2, aplicando relleno de ceros (zero-padding) dinámico para igualar la longitud de la bolsa más grande (ej. $N_{max} = 98$). La validación confirmó que la máscara booleana generada por la función `collate_fn` se integró correctamente en el mecanismo de Gated Attention, anulando matemáticamente los pesos de las instancias de relleno al forzar un valor de $-\infty$ antes de la función `Softmax`.

Decisión Arquitectónica: Se da por validada la integridad del pipeline de datos. MobileNet V2 extrae correctamente los vectores latentes y el modelo emite tensores de clasificación estructurados para las clases [Granulación, Fibrina, Callo]. El flujo está listo para la fase de optimización con BCEWithLogitsLoss.

Estandarización con torchmil y Generación de Heatmaps Anatómicos

Fecha: 9-10 de Abril de 2026

Contexto/Duda: Tras validar el padding dinámico, se identificó la necesidad de transicionar a la librería estandarizada torchmil para el manejo de lotes, asegurando mayor estabilidad que con funciones customizadas. Simultáneamente, era crítico resolver la pérdida de interpretabilidad clínica: visualizar parches aislados con alta atención (α_i) no proporciona contexto anatómico de la úlcera al personal médico.

Análisis y Pruebas: Al integrar torchmil.data.collate_fn, se detectó que esta función exige estrictamente una tupla (Bolsa, Etiqueta) durante el ensamblaje del mini-lote, lo que impedía transportar variables espaciales de forma secuencial. Para el problema visual, se determinó que el algoritmo MIL destruía la topología al aplanar la cuadrícula de la fotografía a un vector 1D (N instancias).

Decisión Arquitectónica: Se desacopló el flujo de procesamiento. Primero, se modificó el generador de bolsas para capturar las dimensiones espaciales antes del aplanamiento y almacenarlas bajo la variable grid_shape en el archivo .pt. Segundo, la clase CoMILDataset se restringió para alimentar exclusivamente tensores a torchmil, implementando un método asíncrono get_metadata() para recuperar la geometría. Con esto, el script de validación logra reconstruir el lienzo anatómico de la úlcera y proyecta los pesos de atención mediante un mapa de calor translúcido. Esta representación visual continua será la evidencia cualitativa primaria en el documento final.

Mejorar el generador de bolsas

Fecha: 17 de Abril de 2026

Contexto/Duda: Optimización de las herramientas de preprocesamiento y visualización para la fase de validación clínica. Se buscaba resolver la rigidez en la toma de datos y la falta

de interpretabilidad anatómica en los tensores.

Análisis y Pruebas: Se identificó que el experto requiere un flujo de trabajo flexible (sesiones múltiples) y dinámico (nuevos tejidos). Asimismo, se implementó un script capaz de hacer un redimensionamiento de parches a pixeles variables para que a futuro se pueda probar el modelo con diferentes tamaños de parches y no solo de 224x224.

Decisión Arquitectónica: Se actualizó el script del generador de bolsas para permitir pausar y reanudar el trabajo automáticamente. Ahora soporta el agregado dinámico de etiquetas (MIML) para tejidos no previstos (ej. tendón). **Reprocesador Multiescala:** Script independiente que cambia el tamaño de los parches a cualquier dimensión (56, 112, etc.) heredando las anotaciones originales y aplicando *Reflection Padding* para evitar bordes negros.

Inspector Académico: Rediseño total del visor con estética para examen profesional. Reconstruye la anatomía de la úlcera, superpone la malla MIL técnica y despliega metadatos detallados del tensor.

Capítulo 9

Conclusiones Preliminares

Hasta este punto, se ha logrado consolidar una base metodológica y arquitectónica sólida que justifica empíricamente por qué el esquema Co-MIL (Continual Multiple Instance Learning) es la vía óptima para sortear la escasez de datos biomédicos etiquetados a nivel píxel en úlceras de pie diabético. Las decisiones clave incluyen la sustitución de transformadores masivos por MobileNet V2 para habilitar un *Memory Pool* más amplio en dispositivos móviles, y la transición hacia un manejo dinámico de la resolución espacial. Se ha abandonado el uso de ventanas deslizantes rígidas en favor de algoritmos de expansión inteligente (*Smart Crop*) con *Reflection Padding*, garantizando la preservación de los gradientes convolucionales sin introducir ruido geométrico. Adicionalmente, la validación del flujo tensorial mediante la estandarización de `torchmil` ha demostrado que la arquitectura es capaz de gestionar tensores de longitud variable (N instancias) aplicando enmascaramiento booleano, logrando generar mapas de calor clínicamente interpretables sobre la geometría anatómica real de la herida.

Trabajo a Futuro

Con la validación estructural de la arquitectura base finalizada, la hoja de ruta técnica para las siguientes fases del proyecto de Práctica Profesional Supervisada se estructura de la siguiente manera:

- **Fase 1: Configuración del Motor de Entrenamiento.** Integración de optimizadores (e.g., AdamW) y formulación de la función de pérdida multi-etiqueta utilizando `BCEWithLogitsLoss`. Se incorporará ponderación de clases (*pos_weight*) para contrarrestar el desbalanceo inherente entre la prevalencia de los distintos tejidos (granulación, fibrina y callo).

- **Fase 2: Procesamiento Masivo y Evaluación MIML.** Anotación interactiva y extracción de bolsas de características para el conjunto completo de más de 260 fotografías clínicas en alta resolución. El rendimiento del modelo se medirá bajo criterios específicos para problemas multi-instancia y multi-etiqueta (MIML) tales como la pérdida de Hamming (*Hamming Loss*), el error superior (*One-Error*) y la precisión promedio.
- **Fase 3: Integración del Aprendizaje Continuo (El componente Ço").** Implementación del búfer de repetición (*Rehearsal Buffer*). El sistema almacenará "Pseudo-Bolsas" históricas representativas (los parches con mayor coeficiente de atención α) para remuestrearlas durante el ajuste con nuevos dominios de pacientes, mitigando de forma efectiva el olvido catastrófico.
- **Fase 4: Refinamiento Espacial (WSSS) y Cuantificación.** Transmutación de los mapas de atención probabilísticos gruesos en máscaras de segmentación densa utilizando Campos Aleatorios Condicionales (*DenseCRF*). Simultáneamente, se integrarán algoritmos de visión clásica para la calibración espacial con marcadores fiduciaros (ArUco), permitiendo proyectar el diagnóstico a mediciones clínicas exactas en cm^2 .
- **Fase 5: Optimización para Inferencia en el Borde (Edge AI).** De cara a su despliegue en entornos de atención primaria con recursos computacionales restringidos, se aplicarán técnicas de compresión y cuantización (e.g., INT8) sobre el modelo base. Esto garantizará una latencia mínima de inferencia en dispositivos móviles sin desbordar la memoria RAM.

Bibliografía

- [1] Kumari P., Chauhan J., Bozorgpour A., Huang B., Azad R., Merhof D. (2025). *Continual learning in medical image analysis: A comprehensive review of recent advancements and prospects*. Medical Image Analysis.
- [2] Barbosa D., Ferreira M., Braz G Jr., Salgado M., Cunha A. (2024). *Multiple instance learning in medical images: a systematic review*. IEEE Access.
- [3] Cassidy B., Kendrick C., Reeves ND., Pappachan JM., Yap MH. (2025). *Deep learning in chronic wound segmentation: a comprehensive review and meta-analysis*. Visual Computer.
- [4] Yap MH., Kendrick C., Cassidy B., et al. (2021). *Diabetic Foot Ulcers Grand Challenge 2021 (DFUC 2021)*. Zenodo. <https://zenodo.org/record/5596986>
- [5] Wang C., et al. (2024). *FUSeg: The Foot Ulcer Segmentation Challenge*. Information, 15(3), 140.
- [6] Ilse M., Tomczak J., Welling M. (2018). *Attention-based deep multiple instance learning*. International Conference on Machine Learning (ICML). <https://arxiv.org/abs/1802.04712>
- [7] Sandler M., Howard A., Zhu M., Zhmoginov A., Chen L. C. (2018). *MobileNetV2: Inverted Residuals and Linear Bottlenecks*. CVPR. <https://arxiv.org/abs/1801.04381>
- [8] Dhar M. K., Wang C., Patel Y., Zhang T., Niezgoda J., Gopalakrishnan S., Chen K., Yu Z. (2024). *Wound Tissue Segmentation in Diabetic Foot Ulcer Images Using Deep Learning: A Pilot Study*. <https://arxiv.org/abs/2406.16012>
- [9] Maldonado Oclica, A. J. (2026). *Evaluación de algoritmos de aprendizaje automatizado para el análisis de úlceras de pie diabético*. Tesina, Facultad de Ciencias, UNAM.
- [10] Li X., Cui Y., Li J., Chan A. B. (2025). *Advancing Multiple Instance Learning with Continual Learning for Whole Slide Imaging*. Aceptado en CVPR 2025. <https://arxiv.org/abs/2505.10649>

-
- [11] Castro-Macías F. M., Sáez-Maldonado F. J., Morales-Álvarez P., Molina R. (2025). *torchmil: A PyTorch-based library for deep Multiple Instance Learning*. arXiv preprint arXiv:2509.08129. <https://arxiv.org/abs/2509.08129>
- [12] Lee B. H., Jeong W., Han W., Lee K., Chun S. Y. (2025). *Continual Multiple Instance Learning with Enhanced Localization*. Aceptado en ICCV 2025. <https://arxiv.org/abs/2507.02395>