

Bitácora de Investigación y Diseño Arquitectónico Co-MIL — Parte IV

Reformulación metodológica y estudio de eficiencia de anotación

Adrián Emiliano Beltrán Fernández

Estudiante de Física Biomédica

Facultad de Ciencias, UNAM

Tutor: Dr. José Eduardo Chairez Veloz

Profesor de Asignatura B, Facultad de Ciencias, UNAM

Ciudad de México, 2026

Documento vivo — última actualización: 6 de septiembre de 2026

Resumen

Esta parte continúa el registro cronológico iniciado en `co_mil_bitacora.pdf` (Parte I), `co_mil_bitacora_parte2.pdf` (Parte II) y `co_mil_bitacora_parte3.pdf` (Parte III). Documenta el **cambio de estrategia** acordado en la reunión con el tutor y la asesoría clínica del 27 de agosto de 2026 — pasar de anotación débil por cajas a **anotación densa (máscaras de tejido)** — y el trabajo de la primera semana de septiembre: una investigación dirigida de estado del arte verificada fuente por fuente, el reencuadre del proyecto en tres brazos de supervisión, y un primer estudio computacional sobre el conjunto de datos público DFUTissue que establece un baseline supervisado y una primera medición de *cuántas máscaras densas hacen falta* para localizar tejidos. El catálogo de tejidos y el protocolo de anotación quedan como propuesta a confirmar en una sesión con la Facultad de Enfermería y Obstetricia (FENO) de la UNAM, aún sin fecha al cierre de esta parte.

Índice general

1. Reformulación tras la reunión del 27 de agosto de 2026	2
1.1. 27 de agosto de 2026	2
1.2. 2 de septiembre de 2026	3
1.3. Trabajo computacional sobre datos públicos (DFUTissue)	7
1.4. Plan de trabajo y estado	12
1.5. Decisiones tomadas (para no reabrir la discusión)	13
1.6. 6 de septiembre de 2026	13
1.7. 6–7 de septiembre de 2026 — Prototipo de aprendizaje continuo (objetivo 3)	15

Capítulo 1

Reformulación tras la reunión del 27 de agosto de 2026

1.1. 27 de agosto de 2026

Reunión de seguimiento con el tutor y la asesoría clínica. *Asistieron el Dr. José Eduardo Chairez Veloz (tutor) y el Dr. Gerardo, el especialista clínico que participó en la anotación de las primeras imágenes del lote. Reunión de carácter informal, apoyada en una presentación visual de 11 diapositivas publicada como página web.*

El tutor planteó un cambio de fondo en la estrategia de anotación, motivado por el hallazgo de atención plana documentado en la Parte III (mediana de contraste de atención $\approx 0,04$ en escala 0–1, con el 97.8 % de las bolsas de prueba conteniendo un solo tipo de tejido). Las decisiones y observaciones de la reunión:

- **Anotación densa desde ahora.** Se abandona la anotación por cajas delimitadoras (`generador_bolsas.py`) y se adopta la anotación por *contorno de cada tejido* (polígonos, máscara a nivel de píxel), al estilo del artículo previo del grupo. De una anotación densa se derivan de forma automática y consistente todas las versiones más simples (etiqueta por imagen, máscara binaria tejido/no-tejido); al revés no es posible.
- **Herramienta: MATLAB Image Labeler** (versión web). Funciona en cualquier equipo con navegador — incluidos los que no usan Windows, resolviendo la incompatibilidad que impidió al Dr. Gerardo colaborar de forma remota hasta ahora — y tanto el tutor como el autor cuentan con licencia. Integra asistencia por *Segment Anything Model* (SAM) para acelerar el trazado.
- **Catálogo reducido.** No las 12 clases del catálogo actual, sino solo las de mayor relevancia clínica y que los modelos distinguen mejor. La cantidad y elección exactas quedan para acordar con la asesoría clínica.
- **Clasificación binaria.** Además de la multiclase, una tarea binaria tejido/no-tejido, equivalente a la máscara de herida del artículo previo. Es el resultado más robusto estadísticamente con un conjunto de datos pequeño.

- **Confusión sobre el mallado “estilo CAM”.** El Dr. observó que la malla de instancias del prototipo CAM (Parte III) era mucho más fina que la de los parches recortados a mano y le pareció adecuada. Aclaración registrada: esa finura proviene de los campos receptivos de la red convolucional (la rejilla nativa del mapa de características, ~ 32 veces menor que la entrada), no de la anotación; un mapa puede verse detallado y ser incorrecto — de hecho la primera corrida del rediseño CAM dio $\text{AUC-ROC} \leq 0,5$ en clasificación.
- **Colaboración con enfermería.** El tutor gestionó el apoyo de la Facultad de Enfermería y Obstetricia (FENO) de la UNAM. En la sesión prevista, las especialistas en tejidos capacitarían al equipo en su identificación clínica y el equipo del proyecto explicaría el protocolo de anotación digital. (Al 6 de septiembre esa sesión sigue sin fecha.)

1.2. 2 de septiembre de 2026

Investigación dirigida de estado del arte, verificada fuente por fuente. *Antes de comprometer la nueva estrategia se realizó una revisión dirigida sobre tres preguntas concretas, con cada cita comprobada de forma independiente contra la fuente primaria (arXiv, PubMed, sitios de editoriales). Notas completas archivadas en el material de proceso del autor.*

- **Localización de tejidos con supervisión débil o parcial.** A la escala de datos de este proyecto (decenas a un par de centenas de imágenes) y con máscaras densas disponibles, el estado del arte para localizar es la *segmentación semántica supervisada ligera* (decodificador FPN o U-Net sobre un extractor MobileNetV2). El Aprendizaje Multi-Instancia (MIL) no es la herramienta de localización cuando hay máscaras — es lo que se usa cuando solo hay etiqueta de imagen. Precedente casi idéntico: Kabir *et al.* (2025, arXiv:2502.10652) segmentan 6 tejidos en 147 fotografías macroscópicas de heridas y obtienen Dice $\approx 0,82$ con FPN. Advertencia relevante: los métodos MIL recientes contra el colapso de atención (AEM, MICCAI 2025; ASMIL, 2026) atacan el problema *opuesto* (atención demasiado concentrada en laminillas de patología); aplicarlos aquí aplanaría aún más los mapas.
- **Aprendizaje continuo.** El nicho de MIL con aprendizaje continuo tiene apenas cuatro o cinco trabajos, todos sobre laminillas completas de patología salvo uno (Ebrahimi *et al.*, MICCAI-W 2025, células de sangre). Un estudio cuidadoso de *rehearsal* (búfer de repetición) es una contribución legítima, no una reimplementación. Li *et al.* (CVPR 2025) reportan que en MIL con atención el olvido catastrófico se concentra en las capas de atención.
- **Conjuntos de datos y huecos del campo.** Solo existen dos conjuntos de datos de *tejidos* de herida disponibles públicamente en el mundo: DFUTissue (110 imágenes, 3 clases) y WoundTissue (147 imágenes, 6 clases). Las revisiones recientes (Yu *et al.*, *Digital Health* 2026 — que cita el trabajo previo del grupo; Reifs Jiménez *et al.*, *J. Med. Syst.* 2025) señalan como carencias explícitas: conjuntos de datos pequeños y homogéneos, poca diversidad de tono de piel, localización menos desarrollada que clasificación, y falta de rigor en la generación del ground truth. **Ningún trabajo de heridas ha publicado**

una curva de eficiencia de anotación, y no existe ningún estudio de aprendizaje continuo en el dominio.

El proyecto reformulado: de “MIL lo es todo” a “MIL es un brazo”. *Reencuadre acordado a partir de la investigación anterior.*

En la Parte III todo el sistema era un modelo MIL con atención, y la localización espacial se esperaba de sus mapas de atención — que resultaron casi planos. Con anotación densa, la localización deja de depender de la atención: se resuelve como segmentación supervisada. El MIL se conserva, pero como el *instrumento* de las variantes de anotación barata, no como el sistema completo. La Figura 1.1 resume la estructura.




Figura 1.1: El proyecto reformulado. De una única anotación densa se derivan tres niveles de etiqueta; tres brazos de entrenamiento las consumen; los tres se evalúan de forma idéntica, contra las máscaras. El brazo mixto (pocas máscaras + muchas etiquetas débiles) es la pregunta central. Encima, el aprendizaje continuo re-entrena el modelo conforme llegan lotes de datos; al final se exporta a un dispositivo de bajo consumo.

La estructura de la tesis queda en seis componentes, alineados con los objetivos del plan y con tres ejes de contribución que no han sido abordados en heridas: (1) un conjunto de datos regional mexicano con diversidad de tono de piel; (2) la frontera de eficiencia de anotación; (3) el aprendizaje continuo.

1. **Conjunto de datos** mexicano (5 clases, multi-anotador) + validación de transferencia entre poblaciones con DFUTissue en las 3 clases compartidas.
2. **Brazo supervisado:** segmentación semántica ligera (FPN + MobileNetV2). La cota alta.

3. **Brazo débil (MIL)**: solo etiqueta de imagen. ¿Hasta dónde llega?
4. **Brazo mixto**: pocas máscaras densas + muchas etiquetas débiles. La curva Dice frente a número de máscaras.
5. **Extensión de aprendizaje continuo**: datos que llegan por lotes; olvido y *rehearsal*.
6. **Factibilidad embebida**: exportación a ONNX, latencia, compromiso multi-tejido vs. binaria.

Catálogo de tejidos propuesto (5 clases). *Propuesta fundamentada, a confirmar en la sesión con la FENO. Detalle completo en [documentación/propuesta_dataset_tejidos_UPD.pdf](#).*

Se propone anotar cinco categorías, elegidas por relevancia clínica para la cicatrización, evidencia en la literatura de que los modelos las distinguen, y prevalencia esperada suficiente (Figura 1.2):

1. **Granulación** (rojo) — tejido que cicatriza; la clase mejor distinguida en toda la literatura (Dice típico 0.70–0.91).
2. **Fibrina / esfacelo** (amarillo) — frena la cicatrización; el tejido del lecho más difícil (Dice 0.33–0.77 según el trabajo).
3. **Tejido calloso** (hiperqueratosis) — propio del pie diabético; ya presente en el trabajo previo y en DFUTissue.
4. **Tejido necrótico / escara** (negro) — indica desbridamiento; alto contraste visual.
5. **Piel perilesional** (intacta o macerada) — presente en *todas* las fotografías, lo que equilibra el conjunto y define directamente la máscara binaria.

Las tres primeras coinciden con DFUTissue y con el artículo previo, lo que habilita la validación cruzada entre poblaciones. Se dejan fuera hueso y tendón expuestos (prevalencia demasiado baja para aprenderlos: 0 y 1 de 204 bolsas en el lote actual) e hiperpigmentación (se confunde con el tono de piel del paciente y puede introducir sesgo). La clasificación binaria tejido/no-tejido sale sola del esquema: el lecho (clases 1–4) es “tejido”; la piel perilesional y el fondo son “no tejido”.




Figura 1.2: Las cinco categorías propuestas, sobre el modelo clínico Rojo–Amarillo–Negro ampliado con callo y piel perilesional. Esquema ilustrativo, no un caso clínico real.

Reconciliación con el artículo previo del grupo. *Se revisó el texto completo de Maldonado-Oclica et al. (2025), del que el autor es coautor, para fijar la vara de medir con precisión.*

Corrección respecto a lo que se había registrado: la segmentación de tejido de ese trabajo **sí** se hizo con aprendizaje profundo (ensamble de ResUnet + Unet++), no con *k-means* — el *k-means* de color era un análisis aparte. Los resultados reportados (sobre DFUTissue, con partición 70:15:15) y los del baseline propio de esta semana (T2, sección siguiente, partición oficial 78:16:16):

Tabla 1.1: Dice por tejido en DFUTissue. “Italia” = Maldonado-Oclica *et al.* (2025); “T2” = baseline de esta bitácora (FPN + MobileNetV2, 4.2 M de parámetros, CPU). Los conjuntos de prueba no son idénticos, así que la comparación es indicativa.

Tejido	Italia (ResUnet+Unet++)	T2 (FPN+MobileNetV2)	Diferencia
Fibrina	0.333	0.455	+0,122
Granulación	0.786	0.874	+0,088
Callo	0.515	0.712	+0,197
Media	0.545	0.680	+0,135

Un modelo ligero, sin optimizar, entrenado en CPU, ya supera al trabajo previo en las tres clases. **Superar sus cifras es alcanzable y no es el reto principal**; se hará como resultado

secundario, con una arquitectura y una receta de entrenamiento mejores. La contribución fuerte de la tesis son los tres ejes ya mencionados, no ganar por unas décimas de Dice.

1.3. Trabajo computacional sobre datos públicos (DFU-Tissue)

Mientras avanza la anotación — que es el camino crítico y depende de terceros — el trabajo de modelado se adelanta sobre conjuntos de datos públicos. El código nuevo vive en `C0-MIL/segmentacion/` y no reemplaza nada del pipeline MIL original.

T1 — conjuntos de datos públicos. *Descarga reproducible con el script `descargar_datos.py` del módulo nuevo.*

DFUTissue (Dhar *et al.*, 2024, arXiv:2406.16012): 110 imágenes de úlcera de pie diabético anotadas por píxel para tres tejidos (fibrina, granulación, callo) más fondo, con partición oficial 78/16/16 y un conjunto adicional de 600 imágenes sin etiquetar. Son regiones de interés recortadas y rellenadas a 256×256 px. El repositorio no declara licencia formal; el uso se condiciona a citar el artículo. **WoundTissue** (Kabir *et al.*, 2025): el repositorio público contiene solo 13 imágenes de muestra — el conjunto completo (147 imágenes, 6 tejidos, con licencia CC BY-NC-SA 4.0) se solicita a los autores por correo.

T2 — baseline supervisado. *`C0-MIL/segmentacion/entrenar_seg.py`.*

Se entrenó un modelo **FPN con extractor MobileNetV2** (4.2 M de parámetros, pensado para despliegue embebido), preentrenado en ImageNet, con pérdida Dice + entropía cruzada, sobre las 78 imágenes de entrenamiento de DFUTissue; 122 épocas, ~ 46 min en CPU. La Figura 1.3 detalla la arquitectura, incluyendo la segunda cabeza de supervisión débil que se usa en el brazo mixto (T3/T4). Resultado sobre las 16 imágenes de prueba oficiales:

Arquitectura del modelo de segmentación de tejidos




Figura 1.3: Arquitectura del modelo de segmentación de tejidos. El extractor MobileNetV2 (inicializado en ImageNet) produce características a cuatro escalas; el decodificador FPN las fusiona y genera un mapa de logits de $4 \times 256 \times 256$. De ese mapa parten dos cabezas: la *densa* (softmax + argmax, con pérdida Dice + entropía cruzada frente a la máscara) y la *débil* (agrupación log-sum-exp por clase, con entropía cruzada binaria frente a la etiqueta de imagen). Un único modelo se entrena con ambas señales: las N imágenes con máscara supervisan la cabeza densa y las $78 - N$ con solo etiqueta, la débil.

Tabla 1.2: T2 — Dice e IoU por clase, split de prueba de DFUTissue.

Clase	Dice	IoU
Granulación	0.874	0.775
Tejido calloso	0.712	0.553
Fibrina	0.455	0.295
Media (tejidos)	0.680	0.541

Interpretación: baseline sano y en el rango de la literatura. La fibrina es el eslabón débil, como en todos los trabajos del área. El techo de referencia en DFUTissue es su propio artículo (Unet + MiT-b3, un modelo ~ 10 veces más pesado): Dice medio $\approx 0,85$.

T3 y T4 — supervisión débil y frontera de eficiencia de anotación. *CO-MIL/segmentacion/entrenamiento*
Responde a la pregunta central del brazo mixto.

Mecanismo (Figura 1.4). Un único modelo FPN + MobileNetV2 se entrena con una mezcla: N imágenes con máscara densa (pérdida de segmentación, comparación píxel a píxel) y las $78 - N$ restantes con solo la etiqueta de qué tejidos contienen. Para estas últimas se agrupa el mapa de logits de cada clase con *log-sum-exp* en un único valor y se compara con la etiqueta mediante entropía cruzada binaria — el mecanismo estándar de segmentación débilmente supervisada: enseña “hay / no hay este tejido”, no dónde. Se barre $N \in \{0, 5, 10, 20, 40, 78\}$: $N = 0$ es supervisión puramente débil (T3); $N = 78$ es supervisión densa completa; la curva

Dice frente a N es la frontera de eficiencia (T4). La evaluación es idéntica en todos los puntos, para que la comparación aísle solo el efecto de la cantidad de anotación densa.




Figura 1.4: El mecanismo de supervisión mixta. Un modelo aprende de dos señales a la vez; el barrido de N produce la curva de eficiencia. La curva mostrada es esquemática.

Resultado (corrida en GPU T4, 5 semillas, 6–7 de septiembre; Figura 1.5). Además de las curvas *mixto* y *solo_supervisado*, se probó la idea del autor de *filtrar* la anotación débil a las imágenes con ≤ 1 o ≤ 2 tejidos presentes (opción `-max_tejidos_debil`, ver §6 de septiembre).

Tabla 1.3: Dice medio en tejidos (split de prueba de DFUTissue), media $\pm$ desviación estándar sobre 5 semillas. *solo*: N máscaras y nada más. *mixto*: N máscaras + las $78 - N$ etiquetas de imagen. La corrida previa de una semilla dio $N = 0$ (débil pura) = 0,07.

N	solo	mixto	mixto ≤ 2	mixto ≤ 1
5	0,38 $\pm$ 0,10	0,38 $\pm$ 0,12	0,35 $\pm$ 0,15	0,31 $\pm$ 0,12
10	0,48 $\pm$ 0,08	0,50 $\pm$ 0,05	0,46 $\pm$ 0,04	0,40 $\pm$ 0,06
20	0,57 $\pm$ 0,06	0,56 $\pm$ 0,05	0,54 $\pm$ 0,05	0,44 $\pm$ 0,05
40	0,63 $\pm$ 0,02	0,55 $\pm$ 0,04	0,54 $\pm$ 0,03	0,55 $\pm$ 0,05
78	0,71 $\pm$ 0,02	0,70 $\pm$ 0,01	—	—




Figura 1.5: Frontera de eficiencia de anotación en DFUTissue (5 semillas, banda = $\pm 1\sigma$). Las curvas «solo máscaras» y «máscaras + todas las etiquetas débiles» son indistinguibles; filtrar la anotación débil la deja por debajo.




Figura 1.6: La misma curva «solo máscaras densas», desglosada por tejido. La fibrina es el cuello de botella y la única clase que sigue mejorando con más máscaras; granulación y callo se saturan en $N \approx 10\text{--}20$.

Lecturas y cautelas:

- **La anotación débil no aporta nada sobre las máscaras densas a esta escala.** Las curvas *mixto* y *solo* coinciden dentro del ruido hasta $N = 20$, y en $N = 40$ la *mixta* es *peor* de forma consistente (0,55 frente a 0,63). Concuerda con la literatura y con la predicción previa: la pérdida log-sum-exp necesita miles de imágenes para dar señal; con 78 solo añade ruido. El encuadre del capítulo pasa de «la supervisión mixta es útil» a «bastan ~ 20 máscaras densas; las etiquetas de imagen baratas no añaden valor a esta escala» — una afirmación más medida, y el resultado negativo es en sí una aportación (nadie lo ha medido en heridas).
- **Filtrar la anotación débil (idea del autor) tampoco ayuda; la empeora.** Las curvas ≤ 2 y sobre todo ≤ 1 quedan por debajo de la *mixta* sin filtrar. El motivo es directo: al filtrar se pasa de 73 imágenes débiles a 12–38, y esa pérdida de datos pesa más que la supuesta señal más limpia. La hipótesis no se sostiene en DFUTissue; queda como pregunta abierta sobre el conjunto de datos propio, donde las regiones de interés (protocolo v1) contienen varios tejidos y hay más imágenes.
- **La curva sólida es solo:** con ~ 20 máscaras densas (26 % de las imágenes) se recupera el ~ 78 % del desempeño máximo; con ~ 40 (51 %), el ~ 87 %. Con supervisión puramente débil ($N = 0$, corrida previa) no localiza (Dice 0.07).

- La fibrina es el cuello de botella (Figura 1.6).
- **Varianza alta a N bajo** (desviación 0.10–0.15): con un conjunto pequeño, qué imágenes caen en el subconjunto «con máscara» influye mucho. La media sobre 5 semillas ya es estable en la conclusión cualitativa.

Receta de entrenamiento reforzada y comparación de arquitecturas. *Experimentos 2 y 3 del cuaderno, sobre supervisión densa completa (78 máscaras).*

Receta reforzada (aumentación fuerte + pérdida Tversky + sobre-muestreo de las imágenes con fibrina), FPN + MobileNetV2, 3 semillas: Fibrina $0,589 \pm 0,05$, Granulación $0,881 \pm 0,01$, Callo $0,683 \pm 0,02$, **media** $0,718 \pm 0,015$. Sube la media del baseline T2 (0,680) unos cuatro puntos, todo el mérito de la fibrina (+0,13; el callo baja un poco). Supera al artículo previo del grupo en las tres clases (+0,17 de media; los conjuntos de prueba no son idénticos).

Arquitecturas (misma receta, una semilla): FPN + MobileNetV2 (4.2 M) media 0,703; SegFormer-B0 (3.7 M) 0,720; Unet + EfficientNet-B0 (6.3 M) 0,739; Unet++ + ResNet34 (26 M) 0,733. **El modelo pensado para dispositivo pierde solo 0,02–0,04 de Dice frente a modelos hasta seis veces mayores** — argumento a favor del objetivo de factibilidad embebida. Hay margen para elegir un mejor extractor ligero (EfficientNet-B0, SegFormer-B0) más adelante.

1.4. Plan de trabajo y estado

Camino crítico y trabajo en paralelo. *Registro para no repetir la discusión.*

- La **anotación densa** es el camino crítico y no depende por completo del autor (participan la FENO y el Dr. Gerardo). Estimación realista: semanas a un par de meses para 60–150 imágenes con asistencia y SAM.
- **En paralelo, desde ya**, sobre datos públicos: baselines de segmentación (hecho, T2), el estudio de eficiencia con varias semillas y la ablación de supervisión débil (en curso, en GPU), un prototipo de aprendizaje continuo, y la factibilidad embebida. Todo esto ya es material de capítulos.
- **Bloqueado hasta la sesión con la FENO** (aún sin fecha): fijar el catálogo de 5 clases y los criterios de anotación; a partir de ahí, la versión definitiva del protocolo y la reescritura de la hoja de ruta.
- Si el componente de aprendizaje continuo resulta demasiado ruidoso con el tamaño de datos disponible, se presenta como diseño completo + resultados parciales + trabajo futuro, y aun así la tesis se sostiene sobre el conjunto de datos, la eficiencia de anotación y la factibilidad embebida.

Diagramas y material visual. *Estado del material figurativo tras el pivote.*

Figuras ya generadas para esta parte y para la propuesta clínica, todas versionadas en `documentación/figuras/` y construidas con `matplotlib` a partir del código real: `fig_arquitectura_segme` (nivel publicación, Figura 1.3), `fig_proyecto_reformulado`, `fig_supervision_mixta`, `fig_curva_eficie`, `fig_esquema_5_tejidos`, `fig_debil_vs_fuerte`, `fig_flujo_anotacion`. Pendiente: actualizar el diagrama del pipeline de desarrollo (`fig_pipeline_estado_actual`) para reflejar los tres brazos y la anotación densa. El diagrama antiguo de arquitectura (`fig_arquitectura_modelo`, red MIML de K ramas) y el del mecanismo de atención (`fig_mecanismo_atencion_mil`) se conservan como referencia del brazo débil.

1.5. Decisiones tomadas (para no reabrir la discusión)

- Anotación densa (polígonos por tejido) en MATLAB Image Labeler. La GUI de cajas (`generador_bolsas.py`) se deprecia.
- Catálogo propuesto de 5 clases: granulación, fibrina/esfacelo, callo, necrótico, piel perilesional — a confirmar con la FENO. Las 3 primeras coinciden con DFUTissue.
- La localización se resuelve como segmentación semántica supervisada ligera. Las alternativas MIL contra el colapso de atención (AEM, ASMIL) quedan descartadas: atacan el problema opuesto.
- MIL se conserva como instrumento de los brazos de anotación barata (débil y mixto) y como vehículo del componente de aprendizaje continuo.
- El artículo previo del grupo es la vara de medir, no la meta central: superarlo en Dice de tejido es alcanzable y se reporta como resultado secundario.
- Se trabaja sobre el mismo repositorio; los commits del proyecto se hacen sin líneas de atribución de herramientas de asistencia.

1.6. 6 de septiembre de 2026

Estado clínico: sin avance desde el 27 de agosto. *Registro de situación.*

Al 6 de septiembre **no ha habido ninguna reunión** desde la del 27 de agosto: la sesión con la Facultad de Enfermería y Obstetricia (FENO) de la UNAM sigue sin fecha confirmada, y el catálogo de cinco tejidos continúa siendo una propuesta sin validar clínicamente. El trabajo de esta semana es, por tanto, íntegramente computacional sobre el conjunto de datos público DFUTissue. El estudio de eficiencia se ejecutó esta noche en GPU (Google Colab, T4); sus resultados están incorporados arriba, en la sección «Trabajo computacional sobre datos públicos» (experimentos 1, 2 y 3).

Filtro de la anotación débil por número de tejidos. *Idea del autor, implementada en `CO-MIL/segmentacion/entrenar_eficiencia.py` (opción `-max_tejidos_debil`).*

En el brazo mixto, las imágenes sin máscara aportan solo su etiqueta de imagen (qué tejidos contienen) a través de la pérdida débil (agrupación log-sum-exp por clase + entropía

cruzada binaria). Una imagen que contiene los tres tejidos produce la etiqueta $[1, 1, 1]$: esa pérdida se satisface de forma trivial y no obliga al modelo a distinguir nada. Una imagen con un solo tejido produce $[1, 0, 0]$, que sí fuerza a empujar hacia abajo la activación de las otras dos clases en toda la imagen — señal informativa. La hipótesis es que *restringir* el brazo débil a las imágenes con pocos tejidos presentes puede dar una señal más útil por imagen, aunque a costa de usar menos imágenes.

Se añadió la opción `-max_tejidos_debil k`: en el brazo mixto solo se usan como débiles las imágenes sin máscara con $\leq k$ tejidos presentes (una clase «está presente» si ocupa al menos 64 píxeles, para no contar como tejido una astilla de anotación). Acepta una lista (`none, 1, 2`) que genera varias curvas en una sola corrida; las N imágenes con máscara nunca se filtran. La opción `-dir_salida` reutiliza una carpeta de resultados y *reanuda* el barrido saltando las corridas ya hechas, para poder partir el estudio entre sesiones de Colab. **Resultado: el filtro no ayuda, la empeora** (tabla y discusión en la sección de resultados arriba). El motivo es que la reducción de datos pesa más que la señal más limpia.

Cautela por el tamaño de DFUTissue. La distribución de tejidos por imagen en el conjunto de entrenamiento (78 imágenes) es:

Tabla 1.4: N^o de imágenes de entrenamiento de DFUTissue según cuántos tejidos contienen.

Tejidos presentes en la imagen	N ^o de imágenes
1 tejido (Fibrina 3, Granulación 4, Callo 5)	12
2 tejidos	26
3 tejidos	40

El filtro ≤ 1 deja como mucho 12 imágenes débiles (y varias caen dentro del subconjunto con máscara según la semilla), así que solo es informativo a N bajo (5, 10); el filtro ≤ 2 deja ~ 38 y es informativo hasta $N \approx 20$. Sobre el conjunto de datos propio, cuyas regiones de interés (protocolo v1) suelen abarcar varios tejidos, la situación puede ser distinta.

Reestructuración del cuaderno de Colab. *CO-MIL/segmentacion/colab_estudio_dfutissue.ipynb*

El cuaderno se dividió en bloques (uno por semilla o grupo de semillas para el experimento 1, más un bloque para los experimentos 2 y 3) para que cada uno quepa en una sesión de Colab (~ 75 –90 min en T4). Gracias a `-dir_salida`, todos los bloques acumulan en la misma carpeta de Google Drive y reanudan. El estudio de eficiencia corrió completo en segundo plano (bloques A/B/C/A2, semillas 42/1/7/2/3), más los experimentos 2 y 3; las cifras de arriba son sobre esas 5 semillas.

Recorte de la región de interés para el brazo débil — evaluado, pospuesto. *Segunda parte de la idea del autor.*

Las imágenes de DFUTissue ya son regiones de interés recortadas (mediana ~ 134 px de lado) rellenas a 256×256 : ~ 73 % del lienzo es relleno y la clase fondo ocupa el 92 % de los píxeles. Recortar más ajustado reduciría ese fondo irrelevante, pero: (i) es una segunda variable que ensucia la curva de eficiencia; (ii) obligaría a re-ejecutar el baseline supervisado con el mismo recorte para que la comparación sea limpia; (iii) el fallo de fondo del brazo

débil — que la etiqueta de imagen no lleva información espacial — no lo resuelve un recorte, solo reduce holgura a la pérdida log-sum-exp; (iv) rompe la comparabilidad con las cifras publicadas de DFUTissue. Se pospone: la prueba natural es sobre el conjunto de datos propio (imágenes con margen real de piel sana, protocolo v1), recortando cada imagen de entrenamiento a la caja envolvente de su máscara más un margen fijo antes del brazo débil, como ablación de una sola figura cuando haya máscaras.

1.7. 6–7 de septiembre de 2026 — Prototipo de aprendizaje continuo (objetivo 3)

Motivación y montaje. *Módulo CO-MIL/continual/. El componente continuo es el que da nombre al proyecto y el de más peso ante el jurado.*

La preocupación de origen del tutor es concreta: la app del trabajo previo, entrenada en un conjunto de datos, **falla** con fotografías de otra población (otros tonos de piel, otra cámara, otro encuadre). Eso es un problema de *generalización entre dominios*, no de olvido catastrófico en el sentido académico. El prototipo aborda ambos.

Montaje. Extractor MobileNetV2 **congelado**; se precálculan una sola vez las características de los parches (rejilla nativa $8 \times 8 = 64$ instancias por imagen); solo entrena la cabeza de atención con compuertas + clasificador por clase, sobre las tres clases compartidas Fibrina, Granulación, Callo. Métricas desde la matriz $R[i, j]$ (F1 en el lote j tras el paso i): ACC, BWT (Lopez-Paz & Ranzato, NeurIPS 2017) y *Forgetting Measure* (Chaudhry *et al.*, ECCV 2018). Estrategias: *naive* (reentrenar sin más, cota inferior), *joint* (reentrenar con todo, cota superior), *experience replay* (búfer de bolsas completas) y *latent replay* (el búfer guarda solo el vector medio 1280-D — $64 \times$ menos almacenamiento, sin imágenes).

Escenarios simulados: el olvido es leve. *Dos formas de simular los lotes sobre DFUTissue.*

- **Domain-incremental** (las clases fijas, cambia la “cámara”). Los sitios se simularon con *shift fotométrico* (balance de blancos, gamma, desenfoque) porque el agrupamiento k -means sobre las características no separa dominios en DFUTissue (silueta $\approx 0,04$). Resultado (6 órdenes $\times$ 5 semillas): el *naive* pierde ~ 3 puntos de F1 y es **inestable** (desv. de la ACC 0,06 frente a 0,016 de las demás; en algún orden el BWT baja a $-0,24$); *experience* y *latent replay* lo estabilizan y alcanzan al oráculo (ACC $\approx 0,81$, BWT ≈ 0).
- **Class-incremental** (la taxonomía *crece*: primero granulación, luego +fibrina, luego +callo). Resultado (6 órdenes $\times$ 3 semillas): *naive* ACC 0,758, *Forgetting* $+0,034$; *experience/latent replay* ACC 0,812, *Forgetting* $-0,024$ (mejoran, no olvidan). Una ablación con cabeza única (sin el aislamiento por clase de la arquitectura Co-MIL) da lo mismo.

Por qué es leve. Con el extractor congelado las características no se mueven, así que lo que la cabeza aprendió de una clase o un dominio sigue siendo computable desde las mismas características más tarde; y la cabeza es tan pequeña que unas decenas de épocas no borran la frontera de decisión anterior. **La elección desplegable (MobileNetV2 congelado)**

resulta ser también la robusta al cambio de dominio — un resultado útil en sí, aunque débil como “problema a resolver”.

El test de dominio REAL: DFUTissue $\rightarrow$ lote mexicano. *CO-MIL/continual/transfereencia.py*. Segundo dominio de verdad: las 185 regiones del lote experto mexicano con etiqueta débil de tejido, reescaladas y pasadas por el mismo extractor congelado.

Tabla 1.5: Transferencia y aprendizaje continuo DFUTissue $\rightarrow$ lote mexicano (5 semillas, F1 de clasificación de imagen). “Olvido DFU” = $R[0, 0] - R[1, 0]$.

	F1 final DFUTissue	F1 final mexicano	Olvido DFU
Solo DFUTissue (referencia)	0,739 $\pm$ 0,023	0,302 $\pm$ 0,014	—
<i>naive</i> (secuencial)	0,017 $\pm$ 0,021	0,319 $\pm$ 0,056	+0,722
<i>joint</i> (acumulativo)	0,751 $\pm$ 0,028	0,319 $\pm$ 0,071	−0,012
<i>experience replay</i>	0,699 $\pm$ 0,039	0,351 $\pm$ 0,072	+0,040
<i>latent replay</i>	0,756 $\pm$ 0,025	0,324 $\pm$ 0,067	−0,017




Figura 1.7: Izquierda: el salto de dominio y qué hace cada estrategia. El *naive* secuencial destruye DFUTissue (0.74 $\rightarrow$ 0.02); *latent replay* lo evita. Derecha: el test del filtro — ni la aumentación fuerte de cámara/color ni la normalización de color mueven el número del lote mexicano.

Lecturas:

- **El olvido catastrófico SÍ es real cuando los dominios difieren de verdad.** El entrenamiento secuencial *naive* colapsa DFUTissue de 0,74 a 0,02. **La repetición latente lo evita por completo** (queda en 0,76) a coste de almacenamiento ~ 0 — guarda vectores, no fotografías de pacientes. Este es el resultado del objetivo 3.

- **Matiz sobre el “salto de 44 puntos”.** La caída $0,74 \rightarrow 0,30$ mezcla dos cosas. Entrenando *directamente* en el lote mexicano débil, el techo de esa tarea es ~ 0.35 (etiquetas débiles ruidosas, solo 11 regiones con callo, distorsión del reensamblado). El modelo de DFUTissue alcanza 0,30 — solo ~ 5 puntos por debajo del techo. La transferencia *pura* es pequeña; la mayor parte del “salto” es que la evaluación mexicana débil es una tarea intrínsecamente más difícil.
- **No es un problema de cámara/color** (`transferencia_filtro.py`, idea del autor). Se midió el salto en cuatro condiciones: base, aumentación fuerte de cámara/color al entrenar, normalización del color de las fotos mexicanas a las estadísticas de DFUTissue, y ambas. El F1 en el lote mexicano se queda en 0,29–0,30 en *las cuatro*. La aumentación sube DFUTissue de 0,74 a 0,81 pero no ayuda a transferir. No hay atajo barato para una población nueva.

Reencuadre del objetivo 3. *A partir de lo anterior.*

El capítulo continuo no será “resolvimos el olvido catastrófico”, sino: (1) se caracteriza el comportamiento incremental de un clasificador de heridas desplegable con extractor congelado — territorio sin publicar en heridas; (2) el olvido es leve mientras los dominios sean cercanos y **catastrófico cuando difieren de verdad**, y la **repetición latente** lo elimina a coste de almacenamiento nulo y compatible con privacidad; (3) adaptar el modelo a una población nueva *no* se logra con filtros ni con una tanda de etiquetas débiles: hace falta anotación densa real del conjunto mexicano y/o mejores características (preentrenamiento auto-supervisado). Si el resultado final resulta ruidoso con el tamaño de datos disponible, se presenta como diseño completo + resultados parciales + trabajo futuro, y la tesis se sostiene sobre el conjunto de datos, la eficiencia de anotación y la factibilidad embebida.

Pendiente: repetir el test de transferencia con *máscaras densas* en lugar de etiquetas débiles — usando la muestra pública de WoundTissue (13 imágenes con máscara) mientras el conjunto mexicano no las tenga — y el experimento de preentrenamiento auto-supervisado.