

Plan de Tesis 2026-2

Continual Multiple Instance Learning (Co-MIL) para el análisis de imágenes de úlceras en pie diabético

1. Objetivos

General:

Desarrollar y evaluar un esquema de Co-MIL para el análisis de úlceras en pie diabético, capaz de actualizar su desempeño conforme incorpora nuevos datos sin olvidar el conocimiento previo, para su posterior implementación en plataformas embebidas de bajo consumo.

El objetivo general de esta Tesis es derivado del proyecto PAPIIT IN115825: Innovaciones tecnológicas en la evaluación oportuna y el manejo de lesiones en pie diabético y sus secuelas en la marcha humana.

Específicos:

- 1) Revisar el estado del arte en Multiple Instance Learning y aprendizaje continuo aplicados al análisis de úlceras de pie diabético, base de datos completamente anonimizada y de acceso libre disponibles en [4], identificando arquitecturas y estrategias recientes que sirvan como base para el esquema Co-MIL.
- 2) Diseñar un modelo base de MIL que integre un extractor de características y mecanismo de agregación, como *attention pooling* o bloques tipo *transformer*, para combinar información de múltiples parches o regiones de interés y emitir decisiones a nivel imagen o paciente.
- 3) Extender el modelo hacia un esquema Co-MIL, incorporando estrategias de aprendizaje continuo, tales como *rehearsal*, regularización o módulos incrementales, que permitan integrar nuevos conjuntos de imágenes y dominios minimizando el olvido catastrófico.
- 4) Evaluar el desempeño de Co-MIL en uno o más conjuntos de datos de imágenes de úlceras de pie diabético, utilizando métricas como AUC, sensibilidad, especificidad y F1-score, comparándolo con modelos supervisados estándar, así como con esquemas de MIL sin aprendizaje continuo.
- 5) Analizar la viabilidad de portar el modelo Co-MIL a plataformas de bajo consumo, por ejemplo en Android, Raspberry Pi u otras, considerando restricciones de memoria, cómputo y latencia, y documentar recomendaciones para su futura implementación embebida en casos de estudio como úlceras de pie diabético o lesiones cutáneas.

2. Impacto social

Las complicaciones de la diabetes generan una carga importante para los sistemas de salud, en especial cuando la detección es tardía. Esto se refleja en mayor riesgo de amputaciones, estancias hospitalarias prolongadas y un impacto directo en la calidad de

vida del paciente. Desarrollar herramientas que apoyen la evaluación temprana y sistemática de estas lesiones puede contribuir a decisiones clínicas más oportunas y a un uso más eficiente de los recursos disponibles.

El esquema Co-MIL propuesto busca avanzar en esa dirección, al explorar modelos que se actualizan de forma continua con nuevas imágenes médicas y se adaptan a la variabilidad real de los pacientes y de los dispositivos de captura. Al mismo tiempo, el énfasis en su futura implementación en dispositivos de bajo consumo, abre la puerta a acercar este tipo de apoyo al diagnóstico a unidades de primer contacto y escenarios de telemedicina, particularmente en entornos con infraestructura limitada.

3. Integración de los conocimientos adquiridos durante la licenciatura

Este proyecto retoma de forma directa lo visto en la licenciatura, como en asignaturas de Algoritmos Computacionales, Física Computacional, Instrumentación Biomédica e Imagenología Biomédica. El diseño del modelo, el entrenamiento y la comparación de resultados permiten aplicar estos contenidos en un problema concreto de imágenes médicas.

Además, la implementación del sistema como prototipo de software y la idea de llevarlo a dispositivos de bajo consumo exigen buenas prácticas de ingeniería de software, uso de repositorios y cuidado de los recursos computacionales. Con ello, la práctica profesional sirve como puente entre la formación teórica y la participación en proyectos reales de investigación y desarrollo tecnológico.

Metodología

La práctica se organizará en varias etapas que combinan revisión teórica, implementación y experimentación con datos reales de imágenes médicas.

1. Revisión y definición del caso de estudio.

En una primera etapa se realizará una revisión dirigida sobre MIL y aprendizaje continuo en imágenes médicas, identificando investigaciones recientes que sean referencia de arquitectura y protocolos de evaluación. Con base en esta revisión, se definirán los casos de estudio y se seleccionarán uno o dos conjuntos de datos públicos adecuados, registrando sus características.

2. Preparación de datos y construcción de *bags*.

Posteriormente se implementará el preprocesamiento de las bases de datos seleccionadas, con procesos de normalización, cambio de tamaño, segmentación en parches o regiones de interés y, cuando sea pertinente, técnicas de aumento de datos. A partir de estos parches se construirán las *bags* propias de MIL, las cuales se definen como los conjuntos de instancias asociadas a una sola etiqueta a nivel imagen o paciente. En esta etapa también se fijarán las particiones de entrenamiento, validación y prueba, evitando fugas de información entre conjuntos.

3. Diseño e implementación del modelo Co-MIL.

Con los datos listos se desarrollará un modelo base de MIL utilizando una biblioteca de *deep learning*. El modelo contempla (1) un extractor de características basado en una red convolucional pre entrenada, (2) un mecanismo de agregación a nivel *bag*, por ejemplo *attention pooling* o bloques tipo *transformer*. Además, (3) una capa de salida para clasificación. Una vez validado el modelo base, se integrarán componentes de aprendizaje continuo tales como *replay* de ejemplos representativos, regularización sobre parámetros o incorporación incremental de nuevas *bags*, para construir el esquema Co-MIL. Se desarrollarán scripts que permitan simular escenarios de llegada progresiva de datos y actualización periódica del modelo.

4. Evaluación experimental y análisis de resultados.

El desempeño del modelo se evaluará en distintos escenarios, primero en un entrenamiento estándar supervisado, luego el MIL sin aprendizaje continuo y finalmente en un esquema Co-MIL. Se calcularán métricas como AUC, sensibilidad, especificidad, precisión y F1-score, junto con curvas ROC y matrices de confusión. Se analizarán los efectos de los distintos mecanismos de aprendizaje continuo, por ejemplo, con y sin *replay*, así como el impacto de añadir nuevos bloques de datos en diferentes momentos, registrando posibles señales de olvido catastrófico y de mejora o deterioro por dominio.

5. Exploración de factibilidad embebida.

Finalmente se estimará la factibilidad de implementación en dispositivos de bajo consumo. Esto incluirá la medición de tamaño del modelo y tiempos de inferencia en un entorno de prueba, y la conversión a formatos ligeros, tales como ONNX o TensorFlow LITE, cuando sea posible. Se documentarán las restricciones de memoria y cómputo esperadas en plataformas como teléfonos móviles o Raspberry Pi, así como ajustes sugeridos a través de la reducción de parámetros, poda o cuantización ligera para una futura integración embebida.

Bibliografía

- [1] Kumari P, Chauhan J, Bozorgpour A, Huang B, Azad R, Merhof D. Continual learning in medical image analysis: A comprehensive review of recent advancements and prospects. *Med Image Anal.* 2025;106:103730. doi:10.1016/j.media.2025.103730.
- [2] Barbosa D, Ferreira M, Braz G Jr, Salgado M, Cunha A. Multiple instance learning in medical images: a systematic review. *IEEE Access.* 2024;12:78409-78422. doi:10.1109/ACCESS.2024.3403538.
- [3] Cassidy B, Kendrick C, Reeves ND, Pappachan JM, Yap MH. Deep learning in chronic wound segmentation: a comprehensive review and meta-analysis. *Vis Comput.* 2025;41:11885-11908. doi:10.1007/s00371-025-04133-y.
- [4] Yap MH, Kendrick C, Cassidy B, et al. Diabetic Foot Ulcers Grand Challenge 2021 (DFUC 2021). Zenodo. 2021. doi:10.5281/zenodo.4646982.



Adrián Emiliano Beltrán Fernández
Estudiante de Física Biomédica
Facultad de Ciencias. UNAM



Dr. José Eduardo Chairez Veloz
Profesor de Asignatura B
Facultad de Ciencias, UNAM