

Propuesta de trabajo: Construcción de un conjunto de datos anotado de tejidos en úlceras de pie diabético

Documento para discusión con el equipo clínico y el tutor

Adrián Emiliano Beltrán Fernández

Estudiante de Física Biomédica, Facultad de Ciencias, UNAM

Tutor: Dr. José Eduardo Chairez Veloz (Facultad de Ciencias, UNAM)

Asesoría clínica: Dr. Gerardo [apellido] y Facultad de Enfermería y Obstetricia, UNAM

Proyecto derivado de PAPIIT IN115825

Ciudad de México, 2 de septiembre de 2026

Versión de propuesta — sujeta a revisión con el equipo médico

Resumen

Este documento propone construir un conjunto de datos (*dataset*) de fotografías clínicas de úlceras de pie diabético (UPD) en el que un equipo de especialistas marque, sobre cada imagen, la localización exacta de cada tipo de tejido. Se explica **qué se pide anotar** (cinco tipos de tejido y una distinción binaria tejido/no-tejido), **cómo se hace** (trazado de contornos asistido por computadora en MATLAB), **por qué conviene hacerlo de esta forma** y **qué valor científico tendría el resultado**: sería apenas el tercer conjunto de datos de este tipo disponible públicamente en el mundo y el primero originado en América Latina. El documento está escrito para ser entendible tanto por personal clínico como por personas con perfil técnico; las secciones más técnicas están señaladas y pueden omitirse sin perder el hilo.

Índice

1. Resumen ejecutivo	1
2. Contexto: qué se está construyendo y por qué	2
3. Qué se le pide anotar al equipo médico	3
3.1. Anotación aproximada (lo anterior) frente a anotación precisa (lo que se propone)	3
3.2. Por qué precisa, y por qué una sola vez	3

4. Los cinco tejidos propuestos	4
5. Cómo se anota, en la práctica	6
5.1. Criterios de anotación a acordar con el equipo clínico	6
5.2. Qué se registra además de la máscara	6
6. Qué se lograría: el conjunto de datos como aporte científico	7
6.1. Qué conjuntos de datos existen hoy	7
6.2. Por qué el nuestro sería relevante para el estado del arte	8
6.3. Qué se podría lograr con el modelo	8
6.4. Perspectiva de publicación y de tesis	8
7. Plan de trabajo y tiempos aproximados	8
A. Cómo anotar en MATLAB Image Labeler (paso a paso)	9
B. Glosario general	10

1. Resumen ejecutivo

- **Qué se busca.** Un modelo computacional que, a partir de una fotografía de una úlcera, indique *qué tejidos hay y dónde están* (granulación, fibrina, tejido necrótico, callo, y el estado de la piel de alrededor). Esto apoya decisiones clínicas como cuándo desbridar, cómo elegir el apósito y cómo seguir la evolución de la herida.
- **Qué falta hoy.** El proyecto tiene ya toda la parte computacional montada (modelos, entrenamiento, evaluación), pero las anotaciones que se hicieron hasta ahora fueron *aproximadas* (una caja alrededor de la zona) y con criterios que cambiaron a mitad del proceso. Eso limita lo que el modelo puede aprender y, sobre todo, impide *medir* con rigor qué tan bien localiza cada tejido.
- **La propuesta.** Rehacer las anotaciones de forma **precisa**: trazar el contorno real de cada tejido en cada imagen. Se hace una sola vez y de ahí se derivan automáticamente todas las versiones más simples que los experimentos necesiten.
- **Qué se pide al equipo médico.** Trazar, sobre cada foto, el contorno de cinco tipos de tejido, con una herramienta que asiste el trazado (se explica en el Anexo A). Y aportar el criterio clínico para definir bien cada tejido.
- **Qué se obtendría.** Un conjunto de datos mexicano, con diversidad de tonos de piel (algo que los datasets existentes casi no tienen), que llenaría vacíos concretos señalados por las revisiones recientes del área y serviría de base para la tesis y para al menos una publicación.

2. Contexto: qué se está construyendo y por qué

Las úlceras de pie diabético son una de las principales causas de amputación de miembro inferior. Su evaluación en la práctica todavía depende de la inspección visual y de la experiencia de quien observa, lo que introduce variabilidad entre observadores y retrasa la detección de deterioro.

Este proyecto desarrolla un sistema de análisis de imagen que apunta a dos salidas:

1. **Clasificación:** decir qué tejidos están presentes en la foto.
2. **Localización:** decir *dónde* está cada tejido, con una precisión útil para el clínico (idealmente parecida a una segmentación, es decir, píxel por píxel).

La primera salida ya funciona razonablemente. La segunda no: con las anotaciones actuales, el modelo acierta *qué* tejidos hay pero no aprende *dónde* están. La razón, comprobada en los experimentos, es que las anotaciones por caja no le dan al modelo la información espacial que necesita, y además no existe una “respuesta correcta” contra la cual medir la localización. La propuesta de este documento resuelve las dos cosas a la vez.

Nota técnica. El sistema base es un modelo de *Multiple Instance Learning* con atención (Ilse et al., ICML 2018) sobre un extractor *MobileNetV2*. El diagnóstico del problema de localización (mapas de atención casi uniformes; mediana de contraste $\approx 0,04$ en escala 0–1) está documentado en la bitácora del proyecto, Parte III. La anotación densa habilita (i) una referencia para medir localización con Dice/IoU, (ii) supervisión mixta tipo MS-CLAM, y (iii) generar etiquetas débiles de forma consistente y automática.

3. Qué se le pide anotar al equipo médico

3.1. Anotación aproximada (lo anterior) frente a anotación precisa (lo que se propone)

Hasta ahora, anotar una imagen significaba dibujar una **caja rectangular** alrededor de la úlcera y escribir una lista de los tejidos presentes. Es rápido, pero la caja no distingue un tejido de otro dentro de ella, e incluye mucha piel sana “de relleno”.

Lo que se propone es **trazar el contorno real de cada tejido** — lo que en computación se llama un *polígono*: una figura cerrada hecha de puntos unidos, como un “une los puntos” alrededor del borde del tejido. El interior de ese contorno queda marcado como ese tejido. La Figura 1 compara las dos formas.




Figura 1: Izquierda: anotación aproximada (una caja + lista de tejidos). Derecha: anotación precisa (el contorno de cada tejido). Esquemas ilustrativos, no casos clínicos reales.

3.2. Por qué precisa, y por qué una sola vez

- **Es consistente.** No depende del criterio del día ni de quién anotó: el contorno de un tejido es el contorno de ese tejido.
- **Permite medir.** Con el contorno real como referencia, se puede calcular con un número objetivo qué tan bien el modelo localiza cada tejido.
- **Se deriva hacia abajo, no hacia arriba.** De una anotación precisa se obtiene automáticamente la lista de tejidos por foto, la máscara binaria tejido/no-tejido, y cualquier otra versión simplificada. Al revés no se puede. Por eso se invierte el esfuerzo una sola vez, en la versión más completa.

4. Los cinco tejidos propuestos

Se propone anotar **cinco categorías**, elegidas por tres criterios simultáneos: (a) relevancia clínica para evaluar la cicatrización; (b) evidencia en la literatura de que los modelos *sí* logran distinguirlas del resto; y (c) que aparezcan con frecuencia suficiente en un conjunto de este tamaño. La Figura 2 y la Tabla 1 las resumen.




Figura 2: Los cinco tejidos propuestos, sobre el modelo clínico clásico Rojo–Amarillo–Negro, ampliado con el callo (propio del pie diabético) y con la piel perilesional. Esquema ilustrativo.

Tabla 1: Las cinco categorías propuestas.

Categoría	Aspecto / definición clínica	Por qué se incluye
1. Granulación	Rojo, granular, húmedo, brillante. Tejido sano que rellena la herida.	Es el tejido que mejor distinguen todos los modelos publicados (Dice típico 0.70–0.91). Señal de cicatrización.
2. Fibrina / esfacelo	Amarillo o blanquecino, fibroso o viscoso, adherido al lecho.	Marca estancamiento de la cicatrización y es criterio de limpieza/desbridamiento. Es el tejido más difícil del lecho, pero medible (Dice 0.66–0.77 en trabajos recientes).
3. Tejido necrótico / escara	Negro o pardo oscuro, seco y duro (escara) o húmedo.	Indica necesidad de desbridamiento y riesgo de infección. Alto contraste visual $\Rightarrow$ los modelos lo distinguen bien cuando hay ejemplos suficientes.
4. Callo (hiperqueratosis)	Reborde pálido, engrosado y seco en el margen de la herida.	Propio del pie diabético; su presencia y grosor tienen valor pronóstico. Ya estaba en el trabajo previo del grupo y en el dataset público DFUTissue.
5. Piel perilesional	La piel inmediatamente alrededor de la úlcera: intacta, o <i>macerada</i> (blanca, reblandecida por humedad).	Central para el manejo del borde y la elección del apósito. Está en <i>todas</i> las fotos, lo que equilibra el conjunto de datos, y define directamente la máscara binaria (ver abajo).

Qué se deja fuera, y por qué. El **hueso** y el **tendón** expuestos son clínicamente muy importantes, pero aparecen tan poco en fotografías que ningún modelo logra aprenderlos con un conjunto pequeño; se registran como observación libre pero no como categoría a segmentar. La **hiperpigmentación** se descarta porque se confunde con el tono de piel del paciente y puede introducir sesgo. **Epitelización**, **hipergranulación** y **exudado** se dejan como posibles categorías futuras si el volumen de datos lo permite.

La clasificación binaria (tejido / no-tejido). No es un trabajo aparte: sale sola del esquema de cinco clases. El *lecho* de la herida (categorías 1 a 4) es “tejido”; la piel perilesional (categoría 5) y el fondo de la foto son “no-tejido”. Esta distinción binaria es la que corresponde a la máscara de herida del trabajo previo del grupo, es la más robusta estadísticamente con pocos datos, y sirve de resultado principal; la clasificación de los cinco tejidos es el resultado más detallado y exploratorio.

5. Cómo se anota, en la práctica

La herramienta propuesta es **MATLAB** en su versión web (*Image Labeler*), porque funciona en cualquier computadora con un navegador — incluidas las que no usan Windows — y porque el tutor y el estudiante ya cuentan con licencia. El paso a paso está en el Anexo A.

El flujo completo, de la foto a los datos, se resume en la Figura 3:




Figura 3: De una fotografía clínica a los datos que usan los modelos. El equipo médico solo interviene en el segundo paso (trazar los contornos). Todo lo demás es automático.

5.1. Criterios de anotación a acordar con el equipo clínico

- **Qué incluir y qué no.** Definir, con ejemplos, el límite entre fibrina y esfacelo (¿se unen en una sola categoría?), entre callo y piel perilesional engrosada, y entre maceración y piel sana húmeda.
- **Zonas dudosas.** Acordar qué hacer cuando un área tiene mezcla de tejidos o el borde no está claro: marcar el tejido predominante, o dejar sin marcar.
- **Piel perilesional.** Definir cuánta piel alrededor de la herida se incluye.
- **Consistencia entre anotadores.** Un subconjunto de imágenes (por ejemplo, 15–20) debe ser anotado *de forma independiente por más de una persona*, para medir el grado de acuerdo entre especialistas. Esto no es burocracia: es un requisito de rigor que las revisiones del área señalan que casi nadie cumple, y refuerza mucho la validez del conjunto.

5.2. Qué se registra además de la máscara

Por cada imagen se anota: **quién** la anotó, **cuándo**, de **qué clínica o cámara** proviene, y el **tono de piel del paciente** (escala de Fitzpatrick, si el clínico la puede estimar). Esta

información es necesaria para:

1. auditar que el modelo funcione igual de bien en todos los tonos de piel;
2. el componente de *aprendizaje continuo* de la tesis, que estudia qué pasa cuando los datos llegan por lotes a lo largo del tiempo (de distintos anotadores o clínicas);
3. la trazabilidad que exige cualquier publicación con datos clínicos.

6. Qué se lograría: el conjunto de datos como aporte científico

6.1. Qué conjuntos de datos existen hoy

La Tabla 2 resume los conjuntos de datos publicados de segmentación de heridas. La lección es contundente: **solo existen dos conjuntos de datos de tejidos de herida disponibles públicamente en todo el mundo** (DFUTissue y WoundTissueSeg), ambos pequeños, ninguno con licencia plenamente abierta (uno sin licencia, otro no comercial), ninguno de América Latina, y casi ninguno con diversidad de tonos de piel. Un conjunto propio, publicado con una licencia verdaderamente abierta, sería el más permisivo del área.

Tabla 2: Conjuntos de datos publicados de segmentación de heridas (selección). “Binaria” = solo distingue herida de piel, sin tipos de tejido.

Conjunto	Imágenes	Tejidos anotados	Licencia	Origen
DFUTissue (2024)	110 (+600 sin etiqueta)	3: granulación, caello, fibrina	Sin licencia (uso → citar el artículo)	EE.UU. (Milwaukee)
WoundTissueSeg (2025)	147 (13 públicas; resto a petición)	6: granulación, esfacelo, maceración, necrosis, hueso, tendón	CC BY-NC-SA 4.0 (no comercial)	Mixto
Huttunen et al. (2026)	362	4–5	A petición	Finlandia (solo piel clara)
Morgado et al. (2025)	—	3: granulación, esfacelo, escara	—	Portugal
WING–MTL (2026)	350	4: granulación, esfacelo, epitelio, necrosis	Restringida	Corea del Sur
Zhao et al. (2025)	671	~6	Privada	Asia
FUSeg (2021)	1 210	Binaria	Pública	EE.UU.
DFUC 2022	4 000	Binaria	Acuerdo de uso	Reino Unido
Propuesto (este proyecto)	60–270	5 + binaria	Abierta (planeada)	México, piel diversa

6.2. Por qué el nuestro sería relevante para el estado del arte

- **Sería apenas el tercer conjunto de datos de tejidos de UPD disponible públicamente en el mundo, y el primero de América Latina** — y, publicado con licencia abierta, el más reutilizable de los tres. Aunque tenga “solo” 60–270 imágenes, eso ya lo pone a la par de DFUTissue (110) y WoundTissueSeg (147), que son las referencias del campo.
- **Diversidad de tonos de piel.** Las revisiones recientes (Yu et al., 2026; Reifs Jiménez et al., 2025) señalan explícitamente que los datasets existentes son homogéneos en tono de piel y que esto introduce sesgo. Una cohorte mexicana aporta justo esa diversidad.
- **Permite comparaciones que nadie ha hecho.** Con las tres categorías compartidas (granulación, callo, fibrina) se puede entrenar en México y validar en DFUTissue, y viceversa: es el primer estudio de generalización entre poblaciones para tejidos de herida.
- **Rigor de anotación.** Con anotación por varios especialistas y medida de acuerdo entre ellos, cubre otro vacío que las revisiones nombran (la mayoría de los trabajos no documenta cómo se generó la “respuesta correcta”).

6.3. Qué se podría lograr con el modelo

Como referencia realista: el mejor resultado publicado en tejidos de UPD, con un conjunto privado de 671 imágenes y un modelo pesado, alcanza un promedio (mIoU) del 65 % — con granulación al 80 % y los tejidos raros por debajo del 50 %. El trabajo previo del propio grupo (supervisión densa, más de 1 000 imágenes) reporta granulación 78.6 %, callo 51.5 % y fibrina 33.3 % de Dice. Con un conjunto de 60–270 imágenes no se busca superar esos números, sino: (i) alcanzar un desempeño *binario* (tejido/no-tejido) comparable al del trabajo previo; (ii) cuantificar cuánto de ese desempeño se recupera con menos anotación; y (iii) demostrar que el modelo funciona en una población distinta y en un dispositivo de bajo consumo.

6.4. Perspectiva de publicación y de tesis

El material da, de forma realista, para: **(1)** un artículo describiendo el conjunto de datos y la comparación entre poblaciones; **(2)** un artículo (y el núcleo de la tesis) sobre *eficiencia de anotación* — cuántas anotaciones precisas hacen falta realmente, algo que ningún trabajo de heridas ha medido; y **(3)** como extensión, el análisis de aprendizaje continuo, que no existe en el dominio de heridas.

7. Plan de trabajo y tiempos aproximados

- **Semana 1–2.** Cerrar con el equipo clínico la definición de las cinco categorías y los criterios de anotación. Preparar la herramienta y una guía breve.
- **Semanas 2–8.** Anotación. Empezando por las imágenes ya recopiladas; el Dr. Gerardo y el equipo de la Facultad de Enfermería anotan en paralelo. Subconjunto con doble anotación para medir acuerdo.

- **En paralelo (desde ya).** El trabajo computacional avanza sobre los conjuntos de datos públicos (DFUTissue, WoundTissueSeg), sin depender de que termine la anotación.
- **Semanas 6–12.** A medida que llegan las imágenes anotadas, se incorporan como validación y se corren los experimentos con datos propios.
- **Después.** Redacción de la tesis y del o los artículos.

Qué se pide concretamente al equipo médico en esta etapa: (1) validar o ajustar las cinco categorías propuestas y sus definiciones; (2) acordar los criterios de anotación de zonas dudosas; (3) destinar tiempo a anotar (con la herramienta del Anexo A), incluyendo el subconjunto de doble anotación.

A. Cómo anotar en MATLAB Image Labeler (paso a paso)

Este anexo es una guía preliminar. La versión definitiva incluirá capturas de pantalla y se ajustará a lo que el tutor explique en la sesión de arranque.

Requisitos. Una cuenta de MATLAB con licencia (la comparte el tutor) y un navegador web. No se instala nada. Funciona en Windows, macOS, Linux y ChromeOS.

Pasos.

1. Entrar a matlab.mathworks.com e iniciar sesión.
2. Abrir la aplicación **Image Labeler** (menú *Apps*, o escribiendo `imageLabeler` en la línea de comandos).
3. **Cargar las imágenes:** *Import* → *From File*, seleccionar la carpeta del proyecto.
4. **Definir las etiquetas** (una sola vez): en el panel *ROI Labels*, crear cinco etiquetas de tipo *Pixel label*, una por tejido, con un color distinto cada una: *Granulación*, *Fibrina*, *Necrótico*, *Callo*, *Perilesional*.
5. **Anotar cada imagen:**
 - Seleccionar la etiqueta del tejido en el panel de la izquierda.
 - Usar la herramienta **Polygon** para trazar el contorno: se hace clic en puntos alrededor del borde del tejido y se cierra la figura con doble clic. El interior queda pintado con ese color.
 - Alternativa asistida: la herramienta **Segment Anything Model (SAM)** — disponible en MATLAB R2024a y posteriores — permite hacer *un solo clic* dentro de una región y obtener el contorno propuesto automáticamente; luego se corrige con el mouse. Reduce mucho el tiempo por imagen.
 - Repetir para cada tejido presente en la imagen.

6. **Exportar:** *Export* $\rightarrow$ *To File*. MATLAB genera, por cada foto, una imagen de máscara (PNG) donde cada píxel tiene el color/valor de su tejido.
7. Anotar en la hoja de registro: nombre del anotador, fecha, clínica/cámara y tono de piel.

Glosario mínimo para este anexo.

Polígono

Contorno cerrado formado por puntos unidos; se traza haciendo clic alrededor del borde de una región.

Máscara

Imagen del mismo tamaño que la foto, en la que cada píxel indica a qué tejido pertenece (por color o por número).

SAM (*Segment Anything Model*)

Modelo de inteligencia artificial que, dado un clic dentro de una región, propone automáticamente su contorno. Aquí se usa *solo* para acelerar el trazado manual; no decide qué tejido es.

ROI Región de interés (*region of interest*); en este contexto, cada zona de tejido que se marca.

B. Glosario general

Anotación débil / fuerte

Débil: información aproximada (una caja, una lista). Fuerte: información precisa (el contorno exacto de cada tejido).

Segmentación

Tarea de asignar a cada píxel de la imagen una categoría (aquí, un tejido).

Dice / IoU

Números entre 0 y 1 que miden qué tanto se parece la predicción del modelo a la anotación de referencia. 1 = coincidencia perfecta. Son las métricas estándar del campo.

Clasificación binaria

Distinguir solo dos categorías; aquí, “tejido de la herida” frente a “no tejido de la herida” (piel sana + fondo).

Modelo / entrenar

Un programa que ajusta sus parámetros a partir de ejemplos anotados para luego hacer predicciones sobre imágenes nuevas.

Aprendizaje continuo

Estrategia para que un modelo siga aprendiendo cuando llegan datos nuevos con el tiempo, sin “olvidar” lo aprendido antes.

Escala de Fitzpatrick

Clasificación clínica del tono de piel en seis tipos (I a VI); se usa para verificar que el modelo no tenga sesgo por tono de piel.

Referencias principales

1. Dhar MK, Wang C, Patel Y, et al. *Wound Tissue Segmentation in Diabetic Foot Ulcer Images Using Deep Learning: A Pilot Study* (DFUTissue). arXiv:2406.16012, 2024.
2. Kabir MA, Roy N, Hossain ME, et al. *Deep Learning for Wound Tissue Segmentation: A Comprehensive Evaluation using A Novel Dataset* (WoundTissueSeg). arXiv:2502.10652, 2025.
3. Kabir MA, Dulal R. *WoundFormer: Multi-Scale Spatial Feature Fusion for Multi-Class Wound Tissue Segmentation*. arXiv:2605.19868, 2026.
4. Huttunen E, Kimpimäki T, Salenius JE, et al. *Convolutional Neural Networks in Chronic Wound Segmentation and Tissue Classification Using Real-World Images*. International Wound Journal 23(4):e70912, 2026.
5. Morgado A, Carvalho R, Sampaio AF, Vasconcelos M. *Enhancing chronic wound assessment through agreement analysis and tissue segmentation*. Scientific Reports 15, 2025.
6. Kang H, Oh B, Lee S, et al. *Development of a multi-task learning framework with GradNorm for precise wound tissue analysis* (WING-MTL). PLoS One, 2026.
7. Yu Z, Jiang L, Zhang H, Chen H, Li J. *A clinically aligned multimodal workflow framework for chronic wound assessment*. Digital Health 12, 2026. DOI:10.1177/20552076261462641.
8. Reifs Jiménez D, Casanova-Lozano L, Grau-Carrión S, Reig-Bolaño R. *Artificial Intelligence Methods for Diagnostic and Decision-Making Assistance in Chronic Wounds: A Systematic Review*. Journal of Medical Systems 49, 2025.
9. Wang C, Anisuzzaman DM, Williamson V, et al. *FUSeg: The Foot Ulcer Segmentation Challenge*. Information 15(3):140, 2024.
10. Kendrick C, Cassidy B, Reeves ND, Yap MH, et al. *Diabetic foot ulcers segmentation challenge report: Benchmark and analysis*. Medical Image Analysis 94:103153, 2024.
11. Tourniaire P, Ilié M, Hofman P, Ayache N, Delingette H. *MS-CLAM: Mixed supervision for the classification and localization of tumors in Whole Slide Images*. Medical Image Analysis 85:102763, 2023.
12. Ilse M, Tomczak JM, Welling M. *Attention-based Deep Multiple Instance Learning*. ICML 2018. arXiv:1802.04712.
13. Maldonado-Oclica A, Rios-López R, Beltrán-Fernández A, et al. *AI-Based Mobile App for Segmentation and Tissue Classification on Diabetic Foot Ulcer: A Step Forward in Patient Care*. Springer, 2025. DOI:10.1007/978-3-031-95841-0_47.